UNIVERSIDAD MAYOR DE SAN ANDRES

FACULTAD DE CIENCIAS PURAS Y NATURALES

CARRERA DE INFORMATICA

TESIS DE GRADO

DISEÑO DE UN ALGORITMO PARA LA DETECCIÓN DE SIMILITUD ENTRE CÓDIGOS FUENTE

Para optar por el Título de Licenciatura en Informática

Mención: Ciencias de la Computación

Postulante: Univ. Edson Eddy Lecoña Zarate

Tutor: M.Sc. Jorge Humberto Terán Pomier

La Paz - Bolivia

2022

Índice general

Índice de figuras

Índice de cuadros

Índice de programas

CAPÍTULO 1: MARCO REFERENCIAL

1.1. Introducción

Cheers *et al.* (2021) Explica que la identificación de similitud entre códigos fuente puede servir para varios propósitos, entre ellos están el estudio de la evolución de código fuente de un proyecto, detección de prácticas de plagio, detección de prácticas de reutilización, extracción de código para refactorización del mismo y seguimiento de defectos para su corrección.

En el ámbito académico, los estudiantes de programación durante su proceso de formación elaboran trabajos, proyectos, tareas, ejercicios, etc. de programación, escritos en algún lenguaje de programación. Cuando estas actividades se realizan de forma individual, sirven para medir la capacidad de resolución de problemas y el enfoque lógico de los estudiantes. Por ello encontrar similitud en trabajos de programación presentados por estudiantes puede ser identificado como plagio.

En la actualidad existen herramientas de software para detectar la similitud entre códigos fuente, en las cuales se aplican diferentes métodos para la detección de similitud, a partir de las características de las herramientas, se pudo evidenciar que presentan deficiencias como: sistemas obsoletos, sistemas sin código abierto, procesos complejos para la evaluación de similitud, sistemas incapaces que procesar un grupo grande de archivos, sistemas de difícil configuración e instalación, sistemas que requieren conexión a internet.

El diseño del algoritmo propuesto cuenta con tres fases, la primera fase consiste en la conversion de código fuente en secuencias de tokens (Tokenizacion), esto se realizara mediante conceptos de compiladores, la segunda fase consiste en la comparacion de las secuencias obtenidas mediante conceptos de distancia de edicion (Distancia de Levenshtein), la fase final consiste en el calculo del porcentaje similitud.

En el presente trabajo de tesis se centra en el diseño e implementación de un algoritmo para la detección de similitud entre códigos fuente que tenga buen desempeño, en términos de tiempo de ejecución y precisión.

1.2. Problema

1.2.1. Antecedentes del problema

Un trabajo similar al propuesto es realizado por Anzai y Watanobe (2019) en el que presenta un algoritmo para la detección de similitud llamado “Algoritmo para determinar la distancia

de edición ampliada entre códigos de programa". El algoritmo consiste en tres fases, en la primera fase el código dado es dividido en funciones, en la segunda fase cada función es dividida en bloques, en la tercera fase cada bloque es dividido en tokens y otras tareas de preprocesamiento. La distancia entre dos bloques, es calculado por un algoritmo de programación dinámica, la relación entre bloques y funciones de dos códigos fuente es tratado como el problema de Minimum-Cost-Flow. Para la evaluación del algoritmo, realiza varios experimentos utilizando recursos de un juez de programación en linea. Respecto a la complejidad temporal del algoritmo, se emplea el algoritmo de Bellman-Ford para el calculo de Minimum-Cost-Flow. La complejidad temporal de Bellman-Ford es de $O(V * E)$, donde V es el numero de vértices y E es el numero de aristas, E es igual a V^2 por que el grafo es bipartito y completo, entonces la complejidad temporal de Minimum-Cost-Flow es $O(V^3)$. La complejidad temporal para calcular la distancia de edición extendida entre bloques es $O(L^2)$ donde L es el numero de tokens. La complejidad temporal de dividir las funciones en bloques y realizar el calculo de la distancia entre bloques es $O(M^2 * L^2 + M^4)$ donde M es el numero de bloques. La complejidad temporal para dividir el bloque en funciones y realizar calculo de la distancia entre códigos fuente es $O(N^2 * M^2 + N^2 * M^4 + N^2)$ donde N es el numero de funciones.

Otro trabajo similar es realizado por Popescu y Nicolae (2016), el cual presenta un método para medir la similitud entre paginas web, el método utiliza un algoritmo para calcular la distancia de edición, el valor calculado es usado como métrica de similitud. El algoritmo utiliza las etiquetas HTML de las paginas web para realizar en las operaciones de edición, las operaciones en las etiquetas consisten en eliminar, insertar y reemplazar. Es decir, dados dos archivos HTML la forma de calcular que tan diferentes es contando el numero mínimo de operaciones en las etiquetas, para transformar un archivo en otro.

1.2.2. Planteamiento del problema

Cheers *et al.* (2021) Explica que la identificación de similitud entre códigos fuente, puede servir para varios propósitos como: El estudio de la evolución de código fuente de un proyecto, la detección de prácticas de plagio en el ámbito académico, la detección de prácticas de reutilización, la extracción de código para refactorización del mismo y el seguimiento de defectos para su corrección.

Una manera de ocultar la similitud entre códigos fuente, es mediante la aplicación de métodos de ofuscación. Estos métodos consisten en aplicar cambios léxicos o estructurales al código fuente, con el propósito de que no sean identificados como similares.

Por lo cual contar un algoritmo que calcule de forma eficiente la similitud entre códigos fuente, tomando en cuenta los métodos de ofuscación, es de gran utilidad.

1.2.3. Formulación del problema

¿El algoritmo SCED tiene mejor desempeño frente a los algoritmos de Winnowing-Fingerprint y RKRGST en la detección de similitud entre códigos fuente?

1.3. Objetivos

1.3.1. Objetivo general

Diseñar e implementar el algoritmo SCED para la detección de similitud entre códigos fuente.

1.3.2. Objetivos específicos

- Estudiar los metodos de ofuscación de códigos fuente.
- Estudiar los algoritmos utilizados en las herramientas para la detección de similitud de código fuente.
- Redactar las especificaciones para el algoritmo SCED.
- Evaluar el desempeño del algoritmo SCED realizando las pruebas en trabajos de programación presentado por estudiantes.

1.4. Hipótesis

El algoritmo SCED detecta la similitud entre códigos fuente con una confiabilidad del 95 % frente a los algoritmos de RKRGST y Winnowing-Fingerprint.

1.4.1. Variables Independientes

- El diseño del algoritmo SCED.

1.4.2. Variables Dependientes

- Resultados en la deteccion de similitud entre codigos fuente con una confiabilidad del 95 % frente a los algoritmo de RKRGST y Winnowing-Fingerprint.

1.5. Justificaciones

1.5.1. Justificación Social

En el ámbito académico, los estudiantes de programación durante su proceso de formación elaboran trabajos, proyectos, tareas, ejercicios, etc. de programación, escritos en algún lenguaje de programación. El algoritmo SCED ayudara a docentes de instituciones académicas, en la detección de trabajos similares de programación presentados por estudiantes.

1.5.2. Justificación Económica

El algoritmo SCED para la detección de similitud entre códigos fuente sera de código abierto, por lo cual permitirá que se desarrollen software a bajo costo.

1.5.3. Justificación Tecnológica

El algoritmo SCED para la detección de similitud entre códigos fuente, se puede implementar en jueces de programación para identificar los envíos similares de los usuarios.

1.5.4. Justificación Científica

Con la utilización de trabajos de programación presentados por estudiantes se medirá el desempeño de los algoritmos para la detección de similitud entre códigos fuente. Con los resultados obtenidos se determinará cuál algoritmo es más eficiente en términos de tiempo de ejecución y precisión.

1.6. Alcances y Limites

1.6.1. Alcance Sustancial

- Se diseñará e implementará en Python el algoritmo SCED para la detección de similitud entre códigos fuente.
- Se realizaran las pruebas de similitud con trabajos de programación presentados por estudiantes.
- Se realizarán pruebas para medir el tiempo, espacio de memoria ocupado y eficiencia del algoritmo.

- Se dejará de lado el estudio de métodos para la detección de similitud que aplican técnicas de inteligencia artificial.

1.6.2. Alcance Espacial

- La implementación y las pruebas del algoritmo, se realizaran en una computadora intel i3 de décima generación con 8GB de RAM y 512GB de disco duro.
- La procedencia de los trabajos de programación para las pruebas, son archivos de código fuente enviados por usuarios de un juez de programación.

1.6.3. Alcance Temporal

- En la presente investigación se realizaran las pruebas con archivos de código fuente que fueron presentados al juez desde su despliegue hasta la fecha.

1.7. Metodología

1.7.1. Metodología Experimental

Para el desarrollo del trabajo de investigación se utilizara la metodología científica experimental, esta investigación nos permite la manipulación de una o mas variables. Las siguientes etapas ayudaran a cumplir con los objetivos propuestos.

1. **Recopilación de la información.** En esta etapa se recopilara información necesaria y se estudiara los temas relacionados al diseño del algoritmo.
2. **Diseño del algoritmo.** En esta etapa se diseñara el algoritmo tomando en cuenta los alcances.
3. **Implementación del algoritmo.** En esta etapa se implementara el algoritmo.
4. **Pruebas de funcionamiento del algoritmo en trabajos de cátedra.** En esta etapa se realizara pruebas en trabajos de cátedra presentados por estudiantes.
5. **Análisis de los resultados obtenidos.** En esta etapa se analizaran los datos obtenidos y se realizara la comparación con los datos obtenidos por otros algoritmos.
6. **Conclusiones.** En esta etapa se realizara las conclusiones, se presentaran los resultados finales, y recomendaciones respecto a la investigación.

CAPÍTULO 2: MARCO TEÓRICO

2.1. Conceptos de ofuscación y código fuente

2.1.1. Lenguaje de programación

"Los lenguajes de programación son notaciones que describen los cálculos a las personas y las máquinas. Nuestra percepción del mundo en que vivimos depende de los lenguajes de programación, ya que todo el software que se ejecuta en todas las computadoras se escribió en algún lenguaje de programación" (Aho, 2008, p. 1). Un lenguaje de programación es un lenguaje formal, que mediante un conjunto de instrucciones permite a un programador crear programas. El lenguaje de programación es un sistema estructurado de comunicación conformado por conjuntos de símbolos, palabras clave, reglas semánticas y sintácticas, las cuales sirven para el entendimiento entre un programador y una maquina.

- **Palabra clave.** En los lenguajes de programacion existen palabras clave. Estas palabras no se pueden ser utilizadas para ningun otro proposito.
- **Funciones.** Tambien conocidos como subprogramas, procedimientos o metodos, las funciones son segmentos de codigo separado del bloque principal.
- **Tipos de datos.** En los lenguajes de programacion los tipos de datos son variados, los tipos de datos son atributos que indica la clase de dato que se va manejar. Los datos mas comunes son: Numeros enteros, numeros en coma flotante y cadenas.
- **Operadores.** Son simbolos que indican como manipular los operandos. Los operadores mas comunes son: Aritmeticos, relacionales, asignacion, logicos y tratamiento de bits.
- **Comentarios.** Son secuencias de caracteres que sirven para realizar anotaciones en el codigo fuente.

2.1.2. Código fuente

En informática, se denomina código fuente a la conjunto de lineas de texto que escritas por un programador. Estas lineas de texto representan instrucciones en un lenguaje de programación. Las instrucciones representan los pasos que debe seguir la computadora para la ejecución de un programa específico. El código fuente no es directamente ejecutable por la computadora, este debe ser traducido a otro lenguaje de modo que la computadora pueda interpretarlo. En la traducción se usan compiladores, ensambladores, interpretes y otros.

2.1.3. Ofuscación de código fuente

En computación, la ofuscación de código fuente se refiere al acto de realizar cambios no destructivos en código fuente de un programa. Es decir, se alteran las instrucciones del código fuente manteniendo su funcionamiento original, la ofuscación de un programa se realiza para dificultar su entendimiento, también puede ser utilizado para ocultar la similitud con el programa original. Un ejemplo se muestra en la figura 2.1.

Figura 2.1: Ofuscación de código fuente
Fuente: Elaboración propia.

Una definición formal se encuentra en Collberg *et al.* (1997) que define a la ofuscación de código fuente de la siguiente manera: Dado un programa P, y el programa transformado P'. Se define a T como la transformación de ofuscación como $P \xrightarrow{T} P'$, donde requiere que P y P' mantengan el mismo comportamiento observacional, Ademas si P no puede terminar o termina con errores, entonces P' puede terminar o no, y P' debe terminar si P termina.

2.1.4. Métodos de ofuscación de código fuente

Novak *et al.* (2019) Explica que existen muchos métodos de ofuscación son utilizados para ocultar la similitud, a su vez menciona que en un estudio de 72 artículos se identificaron 25 métodos de ofuscación, y de estos se especificaron 16 métodos distintos. Existen muchos métodos para la ofuscación, a continuación se presentan los métodos mas importantes, cada método tiene su ejemplo de ofuscación en el lenguaje de programacion Python.

- Marzieh *et al.* (2011) Mencionan cambios en el formato del código. Como la agregación o eliminación de: Espacios en blanco, sangrías y saltos de linea. El ejemplo se muestra en los programas 2.1 y 2.2.

Programa 2.1: Cambio del formato del código, original

```
1 a = 5
2 b = 4
3 area = a * b
4 perimetro = 2 * a + 2 * b
5 print(area, perimetro)
```

Programa 2.2: Cambio del formato del código, modificado

```
1 a=5
2 b=4
3 area=a*b
4 perimetro=2*a+2*b
5 print(area,perimetro)
```

- Marzieh *et al.* (2011) Mencionan cambios en los comentarios del código. Como la agregación, modificación o eliminación de los comentarios. El ejemplo se muestra en los programas 2.3 y 2.4.

Programa 2.3: Cambios de comentarios, original

```
1  """ Area y perimetro de un
2  rectangulo """
3  a = 5 # lado A
4  b = 4 # lado B
5  # area de un rectangulo
6  area = a * b
7  # perimetro de un rectangulo
8  perimetro = 2 * a + 2 * b
9  # salida
10 print(area, perimetro)
```

Programa 2.4: Cambios de comentarios, modificado

```
1 """ Rectangulo """
2 a = 5 # lado 1
3 b = 4 # lado 2
4 # area
5 area = a * b
6 # perimetro
7 perimetro = 2 * a + 2 * b
8 # salida de datos
9 print(area, perimetro)
```

- Đurić y Gašević (2012) y Donaldson *et al.* (1981) Mencionan el cambio de los nombres de los identificadores. Es decir, cambios en los nombres de variables, nombres de constantes, nombres de funciones, nombres de clases, etc. El ejemplo se muestra en los programas 2.5 y 2.6.

Programa 2.5: Cambio en los nombres de las variables, original

```
1 a = 5
```

```
2 b = 4
3 area = a * b
4 perimetro = 2 * a + 2 * b
5 print(area, perimetro)
```

Programa 2.6: Cambio en los nombres de las variables, modificado

```
1 s_a = 5
2 s_b = 4
3 s_ar = s_a * s_b
4 s_per = 2 * s_a + 2 * s_b
5 print(s_ar, s_perimetro)
```

- Donaldson *et al.* (1981) Menciona cambios en el orden en las declaraciones de las variables. El ejemplo se muestra en los programas 2.7 y 2.8.

Programa 2.7: Cambio en el orden de declaraciones de variables, original

```
1 a = 5
2 b = 4
3 area = a * b
4 perimetro = 2 * a + 2 * b
5 print(area, perimetro)
```

Programa 2.8: Cambio en el orden de declaraciones de variables, modificado

```
1 b = 4
2 a = 5
3 perimetro = 2 * a + 2 * b
4 area = a * b
5 print(area, perimetro)
```

- Grier (1981) Menciona agregar lineas de código innecesarias. El ejemplo se muestra en los programas 2.9 y 2.10.

Programa 2.9: Agregar instrucciones innecesarias, original

```
1 a = 5
2 b = 4
3 area = a * b
4 perimetro = 2 * a + 2 * b
5 print(area, perimetro)
```

Programa 2.10: Agregar instrucciones innecesarias, modificado

```
1 a = 5
2 b = 4
3 var_aux = 100
4 area = a * b
5 perimetro = 2 * a + 2 * b
6 diagonal = (a * a + b * b) ** 0.5
7 print(area, perimetro)
```

- Whale (1990) Menciona el reemplazo de la llamada de un procedimiento por el procedimiento. El ejemplo se muestra en los programas 2.11 y 2.12.

Programa 2.11: Reemplazo de la llamada a un procedimiento, original

```
1 def calcular(a, b):
2     area = a * b
3     perimetro = 2 * a + 2 * b
4     print(area, perimetro)
5 a = 5
6 b = 4
7 calcular(a, b)
```

Programa 2.12: Reemplazo de la llamada a un procedimiento, modificado

```
1 a = 5
2 b = 4
3 area = a * b
4 perimetro = 2 * a + 2 * b
5 print(area, perimetro)
```

- Whale (1990) Menciona el cambio de la especificación de una declaración. Cambios como: El cambio de las operaciones y el operando, cambio en los tipos de datos. El ejemplo se muestra en los programas 2.13 y 2.14.

Programa 2.13: Cambio de operaciones y operandos, original

```
1 a = 5
2 b = 4
3 area = a * b
4 perimetro = 2 * a + 2 * b
5 print(area, perimetro)
```

Programa 2.14: Cambio de operaciones y operandos, modificado

```
1 a = 5
2 b = 4
```

```
3 area = a
4 area *= b
5 perimetro = 2 * (a + b)
6 print(area, perimetro)
```

- Marzieh *et al.* (2011) Mencionan el cambio de estructuras de control por sus equivalentes. El reemplazo por equivalentes de estructuras repetitivas y condicionales, El ejemplo se muestra en los programas 2.15 y 2.16.

Programa 2.15: Cambio en la estructura repetitiva, original

```
1 a = 0
2 for i in range(10):
3     a = a + i
4 print(a)
```

Programa 2.16: Cambio en la estructura repetitiva, modificado

```
1 a = 0
2 i = 0
3 while i < 10:
4     a = a + i
5     i = i + 1
6 print(a)
```

Bejarano *et al.* (2015) se refiere a los métodos como modificaciones y los divide en dos grupos:

- **Cambios léxicos**. Estos no requieren un análisis gramatical o profundo conocimiento de programación para ser eficaces. Algunos ejemplos son: Eliminar comentarios, cambiar el formato de código fuente y cambiar los nombres de las variables.
- **Cambios estructurales**. Estos requiere conocimiento acerca de los lenguajes y técnicas de programación, estos cambios son altamente dependiente de el lenguaje de programación. Algunos ejemplos son: cambiar las estructuras de control, cambiar el orden de las sentencias, reemplazar la llamada a un procedimiento por el procedimiento, etc.

2.1.5. Niveles de transformación

Una de las investigación mas antiguas respecto a la ofuscación de código fuente, fue desarrollado por Faidhi y Robinson (1987) en su trabajo se refiere a los métodos utilizados para

las ofuscación como transformaciones para ocultar la similitud. Explica que las transformaciones pueden ser divididas en niveles. Donde en niveles bajos se encuentran las transformaciones que realiza un programador novato para ocultar la similitud, y los niveles altos se encuentran las transformaciones que realiza un programador experto para ocultar la similitud. A continuación el detalle de estos niveles de transformación.

- **Nivel 1.** Representa los cambios en los comentarios e indentación.
- **Nivel 2.** Representa cambios de nivel 1, y cambios en los identificadores.
- **Nivel 3.** Representa cambios de nivel 2, y cambios en las declaraciones. Es decir declarar constantes extras, cambiar las posiciones de las variables declaradas.
- **Nivel 4.** Representa cambios de nivel 3, y modificación de los métodos. Es decir cambios en las asignaciones de la funciones, cambiar de funciones por procedimientos, combinar y crear nuevas funciones.
- **Nivel 5.** Representa cambios de nivel 4. y cambios en las sentencias equivalentes. Es decir cambios en las estructuras de control equivalentes un for por un while.
- **Nivel 6.** Representa cambios de nivel 5, y cambios en las decisiones lógica. Es decir cambios en la expresiones.

2.2. Detección de similitud de código fuente

Novak *et al.* (2019) Realizo un estudio sistemático campo de la detección de plagio de código fuente, describe definiciones de plagio, herramientas para la detección de plagio, métricas de comparación, métodos de ofuscación, conjunto de datos para la comparación y algoritmos que utilizan las herramientas.

2.2.1. Clasificacion de algoritmos para la detección de similitud

En su estudio Novak *et al.* (2019) identifica algoritmos basados en estilo, basado en semántica, basado en texto, huellas dactilares, recuento de atributos, basado en estructura, coincidencia de cadenas, marca de agua, basado en historial, basado en XML, código compilado, basado en compresión, basado en grafos, basado en agrupamiento, basado en N-gramas y basado en árboles. También hace menciona que los enfoques basados en estructuras son mucho mejores y que la

mayoría de las herramientas combinan más de un tipo de algoritmo. En el cuadro 2.1 se muestra detalles de estos como el primer y ultimo año de publicación de un algoritmo, el numero de artículos en los que aparecen y si utilizan la tokenización.

Tipo de algoritmo	Ultimo año	Primer año	Nro. de artículos	Tokenización
Basado en estilo	2016	2011	5	2
Basado en semántica	2013	2010	7	5
Basado en texto	2016	1996	9	5
Huellas dactilares	2015	2005	11	4
Recuento de atributos	2015	1980	25	6
Basado en estructura	2016	1980	25	13
Coincidencia de cadenas	2016	1981	26	17
Nuevas categorías identificadas				
Marca de agua	2013	2005	2	0
Basado en historial	2016	2013	2	0
Basado en XML	2012	2010	3	2
Código compilado	2015	2006	5	2
Basado en compresión	2010	2004	6	5
Basado en grafos	2015	2005	10	2
Basado en agrupamiento	2015	2005	11	7
Basado en N-gramas	2016	2006	15	9
Basado en árboles	2015	1988	24	8

Cuadro 2.1: Descripción general de los tipos de algoritmos
Fuente: Novak *et al.* (2019).

Novak *et al.* (2019) Menciona que las tres herramientas principales para la detección de similitud, utilizan los algoritmos de Running-Karp-Rabin Greedy-String-Tiling (RKRGST), Winnowing-Fingerprint (W-F) e implementaciones de tokenización.

2.2.2. Técnicas para la detección de similitud

En su investigación Karnalim y Simon (2019) clasifica las técnicas de detección de similitud en tres categorías: Basadas en conteo de atributos, basadas en estructuras y técnicas híbridas, a continuación se dará una breve descripción de cada una de ellas.

1. **Técnicas basadas en conteo de atributos**. Estas técnicas determinan la similitud comparando las frecuencias de ocurrencias de los atributos del código fuente.

   a) **Técnica estándar de conteo de atributos**. Esta técnica considera similares a dos archivos de código fuente si sus frecuencias de ocurrencias de sus atributos son las mismas. Como los operandos, operadores, espacios en blanco, numero de lineas, comentarios, declaraciones y otros. Uno de los primeros trabajos presentados fue por Ottenstein (1976) en el cual utiliza cuatro métricas de software: El numero de operadores únicos, operandos únicos, operadores y operandos.

   b) **Técnicas basadas en recuperación de información**. Esta técnica se basa en realizar consultas especificas a una gran colección de documentos, Una consulta especifica es un segmento de código o archivo y la colección de documentos son los archivos cuyo contenido es similar al segmento o archivo inicial. Las técnicas basadas en recuperacion de la información (IR) se basan en el análisis semántico latente (LSA), y tiene como objetivo encontrar relaciones entre términos con la ayuda de descomposición en valores singulares. Cosma y Joy (2012) utilizaron LSA para detectar similitud en trabajos realizados por estudiantes obteniendo buenos resultados, sugiriendo que la técnica puede mejorar el rendimiento en las herramientas de detección existente como JPLAG y Sherlock.

   c) **Técnicas basadas en agrupamiento**. En esta técnica los archivos de código fuente similares se muestran en grupos. Moussiades y Vakali (2005) fue el primero en utilizar la técnica que consiste en convertir los archivos en tokens y luego los agrupa utilizando un algoritmo de agrupación.

   d) **Técnicas basadas en clasificación**. Esta técnica aprende a buscar patrones de similitud de código fuente. Yasaswi *et al.* (2017) utilizo su algoritmo de clasificación para detectar la similitud ponderando las características, según el modelo de un lenguaje a nivel de caracteres, el cual se entreno en el código fuente del kernel de Linux.

   e) **Técnicas combinadas con conteo de atributos**. Varias técnicas de conteo de atributos se combinan con otras técnicas para mejorar la detección. En su trabajo Sidorov *et al.* (2017) combina técnicas basadas en recuperacion de información y clasificación, su técnica consiste en convertir los archivos en tokens de N-gramas sobre los cuales se realizara el análisis semántico latente.

2. **Técnicas basadas en estructuras**. Estas técnicas comparan estructuras de dos códigos fuente para determinar su similitud.

a) **Técnicas basadas en emparejamiento de cadenas**. Esta técnica es de las mas antiguas y populares, En su investigación Wise (1992) compara dos archivos de código fuente convirtiéndolos en cadenas de tokens, y para la medición de similitud usa el comando sdiff de UNIX.

b) **Técnicas basadas en emparejamiento de arboles y grafos**. La comparación de arboles o grafos puede llegar a tomar un tiempo considerable, por lo cual esta técnica suele incorporar simplificaciones que reduzcan el tiempo. En su investigación Song *et al.* (2015) calcula la similitud de código fuente de dos programas. Utilizando la información sintáctica del código fuente expresado como un árbol de análisis, la similitud sintáctica entre dos programas se calcula mediante un núcleo de árbol de análisis.

3. **Técnicas híbridas** Estas técnicas combinan las técnicas de recuento de atributos, técnicas basadas en estructuras y otras. con el fin de mejorar la eficacia y eficiencia, para la comparación de similitud entre códigos fuente.

2.2.3. Herramientas para la detección de similitud

Novak *et al.* (2019) describe cuatro características de cinco herramientas que son consideradas las más importantes, en el cuadro 2.2 se muestran las características como: las menciones en artículos, código abierto, interfaz grafica (GUI), sin conexión a internet y el sitio web.

Herramienta	Menciones	Código abierto	GUI	offline	Sitio web
JPLAG	43	Si	Si	Si	jplag.ipd.kit.edu
MOSS	38	No	Si	No	theory.stanford.edu
Sherlock	9	Si	Si	Si	warwick.ac.uk
Plaggie	7	Si	Si	Si	www.cs.hut.fi
SIM	6	Si	No	Si	dickgrune.com

Cuadro 2.2: Descripción general de las características de las herramientas
Fuente: Novak *et al.* (2019).

Ragkhitwetsagul *et al.* (2018) Realizo un estudio sobre métodos y herramientas para la detección de similitud, en el cual identifica las medidas de similitud que utilizan las cinco herramientas mas populares. En el cuadro 2.3 se muestra los detalles de las medidas de similitud que utilizan las cinco herramientas más populares.

Herramientas	Medida de similitud utilizadas
JPLAG	Tokens y Greedy-String-Tiling
MOSS	Winnowing-Fingerprint
Sherlock	Firmas Digitales
Plaggie	Token-Tiling
SIM	Alineamiento de cadenas

Cuadro 2.3: Herramientas con sus medidas de similitud
Fuente: Ragkhitwetsagul *et al.* (2018).

JPLAG

Prechelt y Malpohl (2003) Explica que JPLAG es un servicio web que encuentra programas similares entre un conjunto de programas. Se ha utilizado con éxito para detectar plagio entre los envíos de programas Java de los estudiantes. Está disponible para los lenguajes C, C++ y Scheme, su algoritmo de comparación, se basa en uno conocido como Running-Rabin-Karp Greedy-String-Tiling. Cheers *et al.* (2021) Explica que JPLAG opera aplicando un algoritmo Token-Tiling para cubrir un archivo de código fuente con tokens extraídos de otro. Si dos archivos fuente tienen un alto grado de cobertura, pueden considerarse similares y, por lo tanto, candidatos a plagio. Primero, los archivos de código fuente se convierten en un flujo de tokens. JPlag utiliza su propio conjunto de tokens que abstraen los tokens de lenguaje estándar para evitar hacer coincidir el mismo token con diferentes significados. En segundo lugar, los tokens extraídos se comparan entre archivos para determinar la similitud mediante el algoritmo Running-Karp-Rabin Greedy-String-Tiling, donde los tokens de un archivo se superponen a los de otro dentro de una tolerancia de desajuste. La similitud del programa se evalúa como el porcentaje de tokens de un programa que se pueden colocar sobre otro programa.

MOSS

Hage *et al.* (2010) Explica que MOSS es un Software creado por el profesor Alex Aiken en la universidad de Stanford, siendo el primer servicio que inició en la web, una referencia a nivel mundial. MOSS permite comparar hasta 250 archivos en 25 lenguajes de programación. Pachón (2019) Explica que MOSS no tiene licencia como software libre, el uso de MOSS dentro del ambiente académico es gratuito y ofrecido desde un servidor de Stanford. Es difícil su configuración y tiene poca documentación.

Sherlock

Cheers *et al.* (2021) Explica que Sherlock implementa métodos de comparación de texto y tokenizados. En la herramienta, se compara la similitud de un par de programas 5 veces: en su forma original, se eliminan los espacios en blanco y los comentarios, como un archivo fuente tokenizado. En todos los casos, las comparaciones miden la similitud a través de la identificación de ejecuciones, una secuencia de líneas comunes a dos archivos que pueden verse interrumpidas por anomalías, como líneas adicionales.

Plaggie

Ahtiainen *et al.* (2006) Explica que Plaggie es una aplicación Java independiente que se puede utilizar para comprobar ejercicios de programación Java. La funcionalidad de Plaggie es similar al servicio web JPlag publicado anteriormente, pero a diferencia de JPlag, Plaggie debe instalarse localmente y su código fuente está abierto. Aparentemente, Plaggie es el único motor de detección de plagio de código abierto para ejercicios de Java. Cheers *et al.* (2021) Explica que Plaggie es una herramienta que se afirma que funciona de manera similar a JPlag. Plaggie es una aplicación local en comparación con JPlag que originalmente se proporcionó como un servicio web, no existe una publicación que describa el funcionamiento de Plaggie, sin embargo, al examinar su código fuente, opera sobre representaciones tokenizadas de código que evalúan la similitud mediante Token-Tiling.

SIM

Cheers *et al.* (2021) Explica que SIM analiza programas en busca de similitud estructural mediante el uso de alineación de cadenas. Para dos programas, SIM primero analiza el código fuente creando un árbol de análisis. Luego, la herramienta representará los árboles de análisis como cadenas y los alineará insertando espacios para obtener una subsecuencia común máxima de sus tokens contenidos. La similitud de los programas se evalúa luego como el número de coincidencias.

2.3. Indices de similitud

Magurran (1988) explica que los indices de similitud expresan el grado en que dos muestras son semejantes por las especies presentes en ellas. Estos valores pueden obtenerse con base en datos cualitativos o cuantitativos.

2.3.1. Indice de Sorensen-Dice

El indice de Sorensen-Dice también conocido como el coeficiente de Sorencen. Es un estadístico utilizado para comparar la similitud entre dos muestras. El indice de Sorencen-Dice se define como:

$$S = \frac{2 * |A \cap B|}{|A| + |B|} \tag{2.1}$$

En la ecuacion 2.1 se muestra a: $|A|$ y $|B|$ como el numero de especies en las muestras A y B, $|A \cap B|$ como el numero de especies compartidas por las muestras y S como el indice de similitud y varia entre 0 a 1. Es decir se encuentra en el rango de $[0\,..\,1]$.

2.3.2. Indice de Jaccard

El indice de Jaccard tambien conocido como el coeficiente de Jaccard, Es un estadistico utilizado para medir el grado de similitud entre dos conjuntos. El indice de Jaccard se define como:

$$J = \frac{|A \cap B|}{|A \cup B|} \tag{2.2}$$

En la ecuacion 2.2 se muestra a: $|A \cup B|$ como el numero de especies en las muestras A y B, $|A \cap B|$ como el numero de especies compartidas por las muestras y J como el indice de similitud y varia entre 0 a 1. Es decir se encuentra en el rango de $[0\,..\,1]$.

2.4. Conceptos de compiladores y tokens

2.4.1. Procesador de lenguaje

Un procesador de lenguaje también llamado compilador. Aho (2008) Explica que un procesador de lenguaje es un programa que puede leer un programa en un lenguaje y traducirlo en un programa equivalente en otro lenguaje. Una función importante del compilador es reportar cualquier error en el programa fuente que detecte durante el proceso de traducción.

2.4.2. Análisis Léxico

Una analizador lexico tambien es conocido como Lexer. Aho (2008) Explica que la primera fase de un procesador de lenguaje, se le llama análisis léxico o escaneo. El analizador léxico lee el flujo de caracteres que componen el programa fuente y los agrupa en secuencias significativas, conocidas como lexemas. Para cada lexema, el analizador léxico produce como salida un token.

Estos lexemas son los que pasaran a la siguiente fase, el análisis de la sintaxis. El analizador léxico ignora los espacios en blanco que separan los lexemas. Catalán (2010) Explica que esta fase consiste en leer el texto del código fuente carácter a carácter e ir generando los tokens. Estos tokens constituyen la entrada para el siguiente proceso de análisis. El agrupamiento de caracteres en tokens depende del lenguaje que se va a compilar. Es decir un lenguaje generalmente agrupara caracteres en tokens diferentes de otro lenguaje. Los tokens pueden ser de dos tipos, cadenas específicas como palabras reservadas, puntos y comas, etc., y no específicas, como identificadores, constantes y etiquetas. La diferencia entre ambos tipos de tokens radica en si ya son conocidos previamente o no. El analizador léxico irá ignorando las partes no esenciales para la siguiente fase, como pueden ser los espacios en blanco, los comentarios, etc., es decir, realiza la función de preprocesador en cierta medida. Por lo tanto, y resumiendo, el analizador léxico lee los caracteres que componen el texto del programa fuente y suministra tokens al analizador sintáctico.

2.4.3. Tokenización de codigo fuente

Los tokens son la unidad léxica basica, y los lexemas son las palabras de un codigo fuente. Aho (2008) Explica los pasos para generar un token. Primeramente se leen los lexemas que componen del código fuente y los agrupa en categorías según su función, este proceso es llamado tokenización. En un lenguaje de programación un token puede tener en clases como: constantes, identificadores, operadores, palabras reservadas y separadores. Por ejemplo, suponga que un código fuente contiene la instrucción de asignación: $posicion = inicial + velocidad * 60$. En este ejemplo se ignora los espacios en blanco que separan a los lexemas, y los nombres de los lexemas =, + y * serán considerados como símbolos abstractos. A continuación se muestra el detalle de la tokenización de la instrucción:

- *posicion*: es un lexema, se le asigna al token $[id, 1]$, en donde *id* es un símbolo abstracto que representa la palabra identificador y 1 apunta a la entrada en la tabla de símbolos para *posicion*. La entrada en la tabla de símbolos para un identificador contiene información acerca de éste, como su nombre y tipo.

- =: El símbolo de asignación es un lexema, se al asigna el token [=]. Como este token no necesita un valor-atributo, se omite el segundo componente.

- *inicial*: es un lexema, se le asigna al token $[id, 2]$, en donde 2 apunta a la entrada en la tabla de símbolos para *inicial*.

- +: es un lexema, se le asigna al token [+].

- *velocidad*: es un lexema, se le asigna al token $[id, 3]$, en donde 3 apunta a la entrada en la tabla de símbolos para *velocidad*.
- $*$: es un lexema, se le asigna al token $[*]$.
- 60: es un lexema, se le asigna al token [60].

Finalmente se obtiene los siguientes tokens: $[id, 1][=][id, 2][+][id, 3][*][60]$.

2.5. Conceptos de programacion dinamica y distancia de edicion

2.5.1. Programación dinámica

Cormen *et al.* (2009) Explica que la programación dinámica es un método para la resolución de problemas, el cual resuelve un problema combinando las soluciones de los subproblemas. La programación dinámica se aplica cuando los problemas se superponen, cuando los subproblemas comparten subproblemas, donde un algoritmo de programación dinámica resuelve un subproblemas solo una vez y guarda la respuesta en una tabla, de esta forma evita el trabajo de volver a calcular la respuesta. La programación dinámica se aplica a problema de optimización dichos problemas pueden tener mas de una solución posible, en el cual se desea encontrar el máximo o mínimo, a estas soluciones se llaman solución optima.

Para desarrollar un algoritmo de programación de dinámica se sigue la siguiente secuencia de pasos:

1. Caracterizar la estructura de solución optima.
2. Definir recursivamente el valor de una solución optima.
3. Calcular el valor de una solución optima, normalmente en forma ascendente.
4. Construir una solución optima a partir de la información calculada.

2.5.2. El problema de la distancia de edicion

Cormen *et al.* (2009) explica que el problema de la alineación de cadenas o distancia de edición, consiste en dadas dos cadenas $A = [1 \,..\, n]$ y $B = [1 \,..\, m]$, y un conjunto de operaciones de transformación y sus costos. La distancia de edición de A a B es el costo de la secuencia de operaciones menos costosa que transforma A en B, las operaciones se realizan en los caracteres de la cadena. La distancia de edición es una forma de medir que tan diferentes son dos cadenas entre si.

2.5.3. Tipos de distancia de edicion

Navarro (2001) explica que existen diferentes tipos de distancia de edicion, las cuales se distinguen al permitir diferentes operaciones en las cadenas.

- La distancia de la subsecuencia comun mas larga, permite la inserción y eliminacion.
- La distancia de Levenshtein, permite la eliminacion, inserción y reemplazamiento.
- La distancia de Damerau-Levenshtein, permite la insercion, eliminacion, reemplazamiento y transposicion de dos caracteres adyacentes.

Las primeras referencias de este problema son de los años sesenta y setenta, donde el problema de la distancia de edicion aparece en diferentes campos. En el campo de la biologia computacional, procesamiento de señales y recuperacion de texto. En la biologia computacional, las secuencias de ADN y proteinas se ven como textos extensos sobre alfabetos, estas secuencias representan el codigo genetico de los seres vivos. Por lo cual encontrar secuencias especificas sobre estos textos, son operaciones fundamentales para problemas como el ensamblaje de la cadena del ADN o la deteminacion de que tan diferentes son dos secuencias geneticas. Todo esto se modela como la busqueda de patrones en un texto, como ejemplo se tiene el algoritmo de programacion dinamica de Needleman-Wunsch que resuelve el problema de la alineación global de secuenciasde ADN. En el campo del procesamiento de señales, uno de los problemas es la correccion de errores de transmision. La transmision fisica de señales es propensa a errores, de modo que para asegurar una transmision correcta a travez de un canal fisico, es necesario ser capaz de recuperar el mensaje correcto despues de una posible modificacion introducida durante la transmision. Dado que la modificacion no es conocida se requiere un texto que este mas cercano al mensaje enviado, como ejemplo se tienen algoritmos de programacion dinamica que resuelve el problema de la distancia de Levenshtein. En el campo de la recuperacion de texto, tiene como problema principal la correccion de errores de ortograficos de un texto. Esta es una de las aplicaciones antiguas con mas potencial, como ejemplo se tienen algoritmos de programacion dinamica que resuelven el problema de la distancia de Damerau-Levenshtein que permite transposicion de caracteres adyacentes.

2.6. La distancia de la subsecuencia comun mas larga

La subsecuencia comun mas larga tambien es conocida por sus siglas en ingles como LCS. En Cormen *et al.* (2009) encontramos las siguientes definiciones. Dada una secuencia $X = [x_1, x_2, .., x_m]$, una secuencia $Z = [z_1, z_2, .., z_k]$ es una subsecuencia de X si existe una secuencia

estrictamente creciente $[i_1, i_2, .., i_k]$ de indices de X talque para todo $j = 1, 2, .., k$ se tiene que $x_i = z_j$. Dadas dos secuencias X y Y, se dice que una secuencia Z es una subsecuencia comun de X y Y si Z es una subsecuencia de X y Y. Apartir las definiciones, el problema de la subsecuencia comun mas larga se define como: Dadas dos secuencias $X = [x_1, x_2, .., x_m]$ y $Y = [y_1, y_2, .., y_n]$ se quiere encontrar la subsecuencia comun de longitud maxima de X y Y.

2.6.1. Caracterizacion de la LCS

Dada una secuencia $X = [x_1, x_2, .., x_m]$, se define como el i-ésimo prefijo de X, para $i = 1, 2, .., m$ como $X_i = [x_1, x_2, .., x_i]$. A continuación se muestra el teorema para la subestructura optima de la subsecuencia comun mas larga:

Teorema 2.6.1 (Subestructura optima de una LCS)
Dadas las secuencias $X = [x_1, x_2, .., x_m]$ y $Y = [y_1, y_2, .., y_n]$, y dado $Z = [z_1, z_2, .., z_k]$ como alguna LCS de X y Y.

1. *Si $x_m = y_n$, entonces $z_k = x_m = y_n$ y Z_{k-1} es una LCS de X_{m-1} y Y_{n-1}.*
2. *Si $x_m \neq y_n$, entonces $z_k \neq x_m$ implica que Z es una LCS de X_{m-1} y Y.*
3. *Si $x_m \neq y_n$, entonces $z_k \neq y_n$ implica que Z es una LCS de X y Y_{n-1}.*

Apartir del Teorema 2.6.1, se muestra que la LCS de dos secuencias contiene dentro de ella una LCS de prefijos de las dos secuencias. Por lo cual, el problema de la LCS tiene: Propiedad de subestructura optima, solución recursiva y propiedad de superposicion de subproblemas.

2.6.2. Solucion recursiva de la LCS

El teorema 2.6.1 implica que se debe examinar uno o dos subproblemas cuando se encuentra una LCS de $X = [x_1, x_2, .., x_m]$ y $Y = [y_1, y_2, .., y_n]$. Si $x_m = y_n$, se debe encontrar una LCS de X_{m-1} y Y_{n-1}. Añadiendo $x_m = y_n$ a esta LCS. Si $x_m \neq y_n$ entonces se debe resolver dos subproblemas, buscando una LCS de X_{m-1} y Y, y buscando una LCS de X y Y_{n-1}. Cualquiera de las dos LCS que sea mas larga es un LCS de X y Y. La propiedad de superposicion de subproblemas en el problema de la LCS. se ve al busca una LCS de X y Y, se necesita buscar la LCS de X y Y_{n-1}, y de X_{m-1} y Y. Donde cada uno de estos subproblemas tiene el sub-subproblema de encontrar la LCS de X_{m-1} y Y_{n-1}.

Se define a $c[i, j]$ como la longitud de una LCS de secuencias X_i y Y_j. Si $i = 0$ ó $j = 0$, una de las secuencias tiene longitud cero, y por lo tanto la LCS tiene longitud cero, La subestructura optima de la LCS esta dado por la siguiente formula recursiva.

$$c[i,j] = \begin{cases} 0, & \text{si } i = 0 \text{ ó } j = 0 \\ c[i-1, j-1] + 1, & \text{si } i, j > 0 \text{ y } x_i = y_j \\ max(c[i, j-1], c[i-1, j]), & \text{si } i, j > 0 \text{ y } x_i \neq y_j \end{cases} \tag{2.3}$$

En la formulacion recursiva una condicion en problema restinge cual subproblema se considera. Cuando $x_i = y_j$, se debe considerar el subproblema de buscar la LCS de X_{i-1} y Y_{j-1}, en otro caso se considera el subproblemas de buscar la LCS de X_i y Y_{j-1} y el subproblema de buscar la LCS de X_{i-1} y Y_j.

2.6.3. Calculo de la longitud de la LCS

Apartir de la ecuacion 2.3, se puede escribir una algoritmo de programacion dinamica que calcule la longitud de la LCS de dos secuencias en complejidad temporal de $O(n * m)$. El procedimiento LCS-Length toma dos secuencias $X = [x_1, x_2, .., x_m]$ y $Y = [y_1, y_2, .., y_n]$ como entrada, y almacena los valores $c[i, j]$ en una tabla $c[0..m, 0..n]$, y calcula los valores $c[i, j]$ comenzando de la primera fila y columna y asi sucesivamente hasta llegar a la ultima fila y columna. Tambien almacena valores en una tabla $b[1..m, 1..n]$ que sirve para construir la solucion optima. El procedimiento retorna las tablas b y c, que contienen la longitud de la LCS de X y Y. Donde $c[m, n]$ contiene la longitud de la LCS de X y Y.

LCS-LENGTH(X, Y)

```
 1  m = X.length
 2  n = Y.length
 3  let b[1..m, 1..n] and c[0..m, 0..n] be new tables
 4  for i = 1 to m
 5      c[i, 0] = 0
 6  for j = 0 to n
 7      c[0, j] = 0
 8  for i = 1 to m
 9      for j = 1 to n
10          if x_i == y_j
11              c[i, j] = c[i − 1, j − 1] + 1
12              b[i, j] = "↖"
13          elseif c[i − 1, j] ≥ c[i, j − 1]
14              c[i, j] = c[i − 1, j]
15              b[i, j] = "↑"
16          else c[i, j] = c[i, j − 1]
17              b[i, j] = "←"
18  return c and b
```

Dadas las secuencias $X = [A, B, C, B, D, A, B]$ y $Y = [B, D, C, A, B, A]$ el procedimiento LCS-LENGTH calcula las tablas b y c donde la longitud de la LCS es $b[7, 6] = 4$, las tablas se muestran en la figura 2.2.

	0	1	2	3	4	5	6
0	0	0	0	0	0	0	0
1	0	0	0	0	1	1	1
2	0	1	1	1	1	2	2
3	0	1	1	2	2	2	2
4	0	1	1	2	2	3	3
5	0	1	2	2	2	3	3
6	0	1	2	2	3	3	4
7	0	1	2	2	3	4	4

(a) Tabla c

	0	1	2	3	4	5	6
0	0	0	0	0	0	0	0
1	0	↑	↑	↑	↖	←	↖
2	0	↖	←	←	↑	↖	←
3	0	↑	↑	↖	←	↑	↑
4	0	↖	↑	↑	↑	↖	←
5	0	↑	↖	↑	↑	↑	↑
6	0	↑	↑	↑	↖	↑	↖
7	0	↖	↑	↑	↑	↖	↑

(b) Tabla b

Figura 2.2: Tablas calculadas por el procedimiento LCS-LENGTH
Para dos secuencias $X = [A, B, C, B, D, A, B]$ y $Y = [B, D, C, A, B, A]$, su LCS es igual a 4.
Fuente: Cormen *et al.* (2009).

2.6.4. Construccion de la LCS

Apartir de la tabla b que retorna el procedimiento LCS-LENGTH, se construye una LCS de $X = [x_1, x_2, .., x_m]$ y $Y = [y_1, y_2, .., y_n]$. Comenzando en $b[m, n]$ y siguiendo las flechas, encontramos los elemenos de la LCS en orden inverso. El siguiente procedimiento recursivo imprime una LCS de X y Y. La llamada inicial del procedimiento es PRINT-LCS$(b, X, X.length, Y.length)$.

PRINT-LCS(b, X, i, j)
1 **if** $i == 0$ or $j == 0$
2 return
3 **if** $b[i, j] ==$ "$\nwarrow$"
4 PRINT-LCS$(b, X, i - 1, j - 1)$
5 print x_i
6 **elseif** $b[i, j] ==$ "$\uparrow$"
7 PRINT-LCS$(b, X, i - 1, j)$
8 **else** PRINT-LCS$(b, X, i, j - 1)$

Para la tabla b de la figura 2.2b, este procedimiento imprime $BCBA$. La complejidad temporal del procedimiento PRINT-LCS es de $O(m + n)$.

2.6.5. Intervalo de puntajes de la LCS

Los puntajes que se pueden obtener por el procedimiento LCS-LENGTH se encuentran en el intervalo $[minScore\,..\,maxScore]$. En la figura 2.3 se muestra el intervalo.

Figura 2.3: Rango de puntajes LCS
Fuente: Elaboracion propia.

- El puntaje más alto que se puede obtener es $maxScore = \text{MAX}(|A|, |B|)$. Este puntaje representa que ambas cadenas son exactamente iguales y no se utilizaron operaciones para transformar A en B.
- El puntaje más bajo que se puede obtener es $minScore = 0$. Este puntaje representa que ambas cadenas son distintas y se utilizaron varias operaciones para transformar A en B.

2.7. La distancia de Levenshtein

La distancia de Levenshtein tambien es llamada distancia de edicion. Apartir de las definiciones de Cormen *et al.* (2009) y Halim y Halim (2019), podemos definir la distancia de Levenshtein. Dadas dos cadenas $A = [1\,..\,m]$ y $B = [1\,..\,n]$ y un conjunto de operaciones de transformacion y sus costos, donde las operaciones consisten en insertar, eliminar y reemplazar elementos de las cadenas. La distancia de Levenshtein de A y B es el minimo costo de operaciones que transforma A en B. Los costos de las operaciones de transformacion son las siguientes:

1. Si los caracteres $A[i]$ y $B[j]$ coinciden, entonces no se realizan operaciones se puntua 0.
2. Si los caracteres $A[i]$ y $B[j]$ no coinciden, se realiza la operacion de reemplazar $A[i]$ con $B[j]$, la operacion puntua +1.
3. Si se realiza la operacion de insertar un caracter en $A[i]$, la operacion puntua +1.
4. Si se realiza la operacion de eliminar un caracter en $A[i]$, la operacion puntua +1.

Se define a $\textsc{Lev}(i, j)$ como la puntuacion de la alineacion optima, para los prefijos $A[1\,..\,i]$ y $B[1\,..\,j]$. Donde sus casos base y sus Recurrencias son las siguientes:
Casos base.

- $Lev(0, 0) = 0$, dos cadenas vacias no puntuan.
- $Lev(i, 0) = i$, eliminar la subcadena $A[1\,..\,i]$ para realizar la alineacion, $i > 0$.
- $Lev(0, j) = j$, insertar un caracter en $B[1\,..\,j]$ para realizar la alineacion $j > 0$.

Recurrencias para $i, j > 0$.

- $Lev(i, j) = \textsc{min}(opcion1, opcion2, opcion3)$
  - $opcion1 = Lev(i - 1, j - 1)$, si $A[i]$ y $B[j]$ coinciden.
  - $opcion1 = Lev(i - 1, j - 1) + 1$, si $A[i]$ y $B[j]$ no coinciden.
  - $opcion2 = Lev(i - 1, j) + 1$, eliminar A_i.
  - $opcion3 = Lev(i, j - 1) + 1$, insertar B_j.

El algoritmo de programacion dinamica se concentra en tres posibilidades para el ultimo par de caracteres, probando todas las posibilidades, evitando recalcular los subproblemas superpuestos. Con una funcion de puntuacion sencilla, donde una coincidencia obtiene 0 puntos y un

reemplazamiento, insercion o eliminacion obtienen +1, se muestra el detalle de la alineacion de $A =$ "$ACAATCC''$ y $B =$ "$AGCATGC''$ en la figura 2.4. Inicialmente solo se conocen los casos base, y se rellenan los valores fila por fila de izquierda a derecha. Para rellenar $Lev(i, j)$ donde $i, j > 0$, unicamente se necesita de tres valores: $Lev(i-1, j-1)$, $Lev(i-1, j)$ y $Lev(i, j-1)$. La puntuacion de la alineacion maxima se almacena en la celda inferior derecha.

	0	1	2	3	4	5	6	7
0	0	1	2	3	4	5	6	7
1	1	0	1	2	3	4	5	6
2	2	1	1	1	2	3	4	5
3	3	2	2	2	1	2	3	4
4	4	3	3	3	2	2	3	4
5	5	4	4	4	3	2	3	4
6	6	5	5	4	4	3	3	3
7	7	6	6	5	5	4	4	3

Figura 2.4: Ejemplo del algoritmo de Levenshtein
Ejemplo: A="ACAATCC" y B="AGCATGC", la puntuación de la alineación es igual a 3.
Fuente: Halim y Halim (2019).

2.7.1. Implementacion del procedimiento

En LEVENSHTEIN(A, B) se tiene la implementación en pseudocódigo del algoritmo.

```
LEVENSHTEIN(A, B)
 1  m = A.length + 1
 2  n = B.length + 1
 3  let t[0..m, 0..n] be new table
 4  for i = 0 to m
 5      t[i][0] = i
 6  for i = 0 to n
 7      t[0][i] = i
 8  for i = 1 to m
 9      for j = 1 to n
10          if A[i − 1] == B[j − 1]
11              t[i][j] = t[i − 1][j − 1]
12          else
13              t[i][j] = t[i − 1][j − 1] + 1
14          t[i][j] = MIN(t[i][j], t[i − 1][j] + 1)
15          t[i][j] = MIN(t[i][j], t[i][j − 1] + 1)
16  return t[m − 1][n − 1]
```

La complejidad espacial de este algoritmo de DP es $O(n * m)$ dado que la tabla tiene dimension $n * m$. El rellenado de una celda tiene complejidad temporal de $O(1)$ por lo tanto la complejidad temporal del algoritmo es $O(n * m)$.

2.7.2. Intervalo de puntajes de Levenshtein

Los puntajes que se pueden obtener por el procedimiento LEVENSHTEIN se encuentran en el intervalo $[minScore\,..\,maxScore]$. En la figura 2.5 se muestra el intervalo.

Figura 2.5: Rango de puntajes Levenshtein
Fuente: Elaboracion propia.

- El puntaje más alto que se puede obtener es $maxScore = \text{MAX}(|A|, |B|)$. Este puntaje representa que ambas cadenas son distintas y se utilizaron varias operaciones para transformar A en B.

- El puntaje más bajo que se puede obtener es $minScore = 0$. Este puntaje representa que ambas cadenas son exactamente iguales y no se utilizaron operaciones para transformar A en B.

2.7.3. Reduccion de la complejidad espacial

En Halim y Halim (2019) explica que el truco para reducir la complejidad espacial. Durante el calculo de la solucion de cualquier subproblema solo se necesita la fila anterior y la actual. Se puede ahorrar espacio almacenando solo estas dos filas, con este truco la nueva complejidad espacial sera de $O(\text{MIN}(n, m))$ colocando la cadena con menor longitud como la segunda cadena, para el ahorro de espacio. La complejidad temporal se mantiene en $O(n * m)$, la desventaja de este truco es que no puede reconstruir la solucion optima.

2.7.4. Reduccion de la complejidad temporal

En Halim y Halim (2019) explica que el truco para reducir la complejidad temporal. Con el fin de reducir la complejidad temporal solo resolver los subproblemas que estan adyacentes la diagonal principal de la tabla, a una distancia d, con este truco la nueva complejidad temporal sera de $O(m * d)$, la desventaja de este truco es que no siempre se llega a obtener la alineacion óptima. Para asegurarse de obtener la solucion optima d debe ser igual n.

2.8. Hashing de cadenas

Los algoritmos de hashing ayudan a resolver un monton de problemas, uno de esos problemas consiste en la comparación de dos cadenas de forma eficiente. El algoritmo de fuerza bruta compara las cadenas caracter por caracter, esto tiene como complejidad temporal $O(\text{MIN}(n, m))$ donde n y m son longitudes de las dos cadenas. El hashing de cadenas consiste en asignar a cada cadena un valor entero, y comparar los valores enteros, esto reduce la complejidad temporal en $O(1)$ cuando los valores hash ya fueron calculados previamente. Los valores hash de una cadena s de longitud n se define como:

$$\text{HASH}(s) = \sum_{i=0}^{n-1} s[i] * p^i mod m \tag{2.4}$$

los valores p y m de la ecuacion 2.4 son numeros enteros positivos, donde el numero p es primo y el numero m es un valor lo suficientemente grande, con el fin de evitar colisiones. Una colision sucede cuando $\text{HASH}(s) = \text{HASH}(t)$ donde $s \neq t$.

En COMPUTE-HASH se tiene la implementacion en pseudocódigo del algoritmo para calcular el hashing de cadenas.

COMPUTE-HASH(s)

1 $p = 31$
2 $m = 10^9 + 9$
3 $hash\text{-}value = 0$
4 $p - pow = 1$ **for** each $s_i \in s$
5 $\quad hash\text{-}value = ((hash\text{-}value + s_i) * p\text{-}pow) \,\%m$
6 $\quad p - pow = (p\text{-}pow * p) \,\%m$
7 $\quad$ **return** *hash-value*

CAPÍTULO 3: DISEÑO METODOLOGICO

3.1. Definicion de problemas

Para el diseño del algoritmo se debe tomar en cuenta las transformaciones o métodos de ofuscacion de código de fuente que se presentaron en el capitulo anterior. Una transformación consiste en la modificación en las instrucciones del código con el fin de ocultar la similitud con otro. Estas transformaciones son tratados como problemas a resolverse.

Problema 1. Cambios en el formato del código. Es decir agregar o eliminar, saltos de linea, sangrías o espacios.

Problema 2. Cambios en los comentarios del código. Es decir agregar, eliminar y modificar comentarios.

Problema 3. Cambios en los nombres de los identificadores. Es decir cambiar los nombres de las varibales, constantes, nombres de funciones, nombres de clases, etc.

Problema 4. Cambios en el orden de las declaraciones de las variables.

Problema 5. Agregar instrucciones innecesarias. Es decir agregar declaraciones de variables que no se utilizan en el programa.

Problema 6. Reemplazo de la llamada de un procedimiento por el procedimiento.

Problema 7. Cambios en el orden de los operadores u operandos.

Problema 8. Reemplazo en las estructuras de control por equivalentes.

El problema a resolver es: Dados dos archivos de codigo fuente A y B, donde estos archivos pueden tener o no transformaciones. Se quiere encontrar el porcentaje similitud entre los dos archivos dados.

3.2. Especificación no formal del algoritmo

El algoritmo SCED, tiene como entrada: Dos archivos de código fuente A y B. Como salida un numero en el rango de $[0\,..\,100]$, que representa el porcentaje de similitud entre los dos archivos.

Figura 3.1: Especificación no formal del algoritmo SCED
Fuente: Elaboración propia.

3.3. Diseño del algoritmo

El algoritmo SCED utiliza la distancia de Levenshtein como medida para cuantificar la similitud entre dos archivos de codigo fuente previamente tokenizados, al contar el minimo de operaciones requeridas para transformar un codigo fuente en otro. Las operaciones consisten en insertar, eliminar y reemplazar tokens en los codigos fuente. En la figura 3.2 se muestra el diagrama de funcionamiento del algoritmo, en el cual se muestra las fases del algoritmo. Las fases consisten en: La tokenización de los códigos fuente, mediante un Lexer. El calculo de la distancia de edicion de las secuencias de tokens, Levenshtein. Finalmente el calculo del porcentaje de similitud.

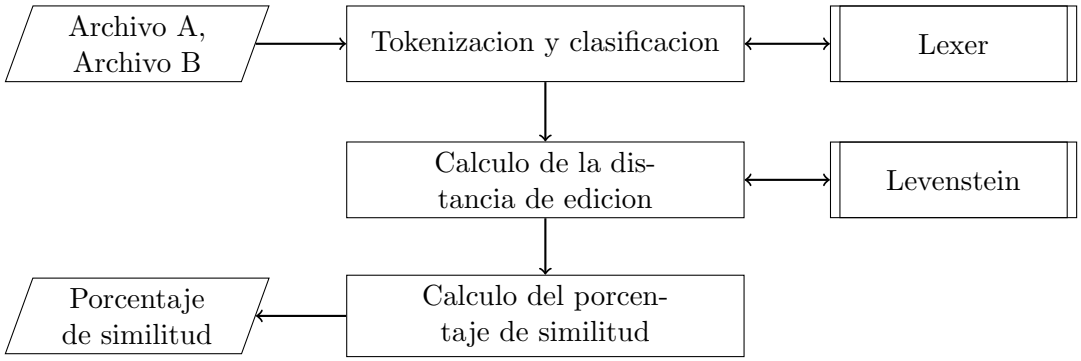

Figura 3.2: Diagrama de funcionamiento del algoritmo SCBM
Fuente: Elaboración propia.

Resumiendo el funcionamiento del algoritmo, el lexer tiene como funcion convertir el codigo fuente de los archivos en secuencias de tokens. Seguido con las secuencia de tokens del primer archivo y segundo archivo, se realizara el calculo de la distancia de edicion de las secuencias de tokens, obteniendo el valor numerico de similitud. Finalmente con el valor numerico se calcula el porcentaje de similitud de los codigos fuente. En la tabla 3.1 se muestra un descripción general de la solucion a los problemas propuestos en la seccion anterior, mediante los algoritmos presentados en el capitulo anterior.

Problema	Algoritmo
1	Lexer
2	Lexer
3	Lexer
4	Distancia de edicion
5	Distancia de edicion
6	Distancia de edicion
7	Distancia de edicion
8	Distancia de edicion

Cuadro 3.1: Descripción general de la solucion de los problemas mediante algoritmos
Fuente: Elaboracion propia.

3.3.1. Tokenización y clasificacion

En esta fase se eliminan los elementos innecesarios que tenga el código fuente como: Los comentarios, saltos de linea que no contengan instrucciones, espacios en blanco, etc. Esto se debe a que estas lineas no serán utilizadas para la comparación de similitud. Al mismo tiempo se realizara la tokenización y clasificacion de los tokens, los tokens generados son tuplas que contienen dos valores: El tipo de token, la cadena del token. A continuacion se muestra la clasificacion de tipos de tokens:

- **Token.text** para datos de tipo texto como: Espacios en blanco y tabulaciones.
- **Token.keyword** para cualquier palabra clave o reservada.
- **Token.name.function** para nombres de funciones.
- **Token.name.variable** para nombres de variables.
- **Token.literal.string** para cualquier cadena.
- **Token.literal.number** para cualquier numero entero o flotante.
- **Token.operator** para cualquier operador.
- **Token.punctuation** para cualquier simbolo de puntuacion.
- **Token.comment** para cualquier comentario.
- **Token.other** para tokens no clasificados.

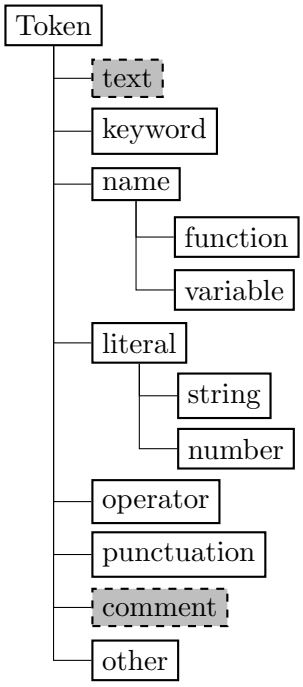

Figura 3.3: Clasificacion de un Token
Fuente: Elaboración propia.

El procedimiento LEXER tiene como entrada un archivo de código fuente *file*, y de salida un arreglo de tokens clasificados.

```
LEXER(file)
1  tokens = GET-TOKENS(file)
2  sequence-tokens = ∅
3  for each token ∈ tokens
4       if IS-VALID(token)
5            token-class = CLASSIFICATION(token)
6            ADD(sequence-tokens, token-class)
7  return sequence-tokens
```

3.3.2. Cálculo de la distancia de edicion de secuencias de tokens

En esta fase se calcula la distancia de edicion. A partir de la definición de la distancia de Levenshtein, podemos definir la distancia de edicion de secuencias de tokens como: Dadas dos secuencias de tokens $A[1\,..\,m]$ y $B[1\,..\,n]$ y operaciones de transformación y sus costos. La distancia de edición entre las secuencias A y B es el costo mínimo de operaciones que transforma A en B. Las operaciones consisten eliminar, insertar y reemplazat tokens en las secuencias.

Para el calculo de la distancia de edicion de secuencias de tokens utilizaremos un algoritmo de programación dinamica, el algoritmo sera adaptado al calculo de la distancia de edicion de secuencias de tokens. El valor calculado por este modulo es la medida de similitud que se utilizara para determinar si dos códigos fuente son similares. Los valores del rango se muestran en la figura 2.5. Donde *minScore* representa que no necesitaron operaciones de transformación, lo que significa que las dos secuencias son exactamente iguales, y *maxScore* representa que se utilizaron el maximo numero de operaciones de transformación, lo que significa que las dos secuencias son muy diferentes.

```
LEVENSHTEIN(A, B)
 1  m = A.length + 1
 2  n = B.length + 1
 3  let t[0..m, 0..n] be new table
 4  for i = 0 to m
 5       t[i][0] = i
 6  for i = 0 to n
 7       t[0][i] = i
 8  for i = 1 to m
 9       for j = 1 to n
10            if TOKEN-COMPARISON(A[i − 1], B[j − 1])
11                 t[i][j] = t[i − 1][j − 1]
12            else
13                 t[i][j] = t[i − 1][j − 1] + 1
14            t[i][j] = MIN(t[i][j], t[i − 1][j] + 1)
15            t[i][j] = MIN(t[i][j], t[i][j − 1] + 1)
16  return t[m − 1][n − 1]
```

3.3.3. Calculo del porcentaje de similitud

A partir del valor obtenido en el calculo de la distancia de edicion, podemos calcular el porcentaje similitud entre dos códigos fuente. Dados dos archivos de código fuente *fileA* y *fileB*, la similitud entre los códigos esta dado por:

$$a = \text{NUM-TOKENS}(\textit{file-}A)$$

$$b = \text{NUM-TOKENS}(\textit{file-}B)$$

$$Percentage = (1 - \frac{\text{GET-EDIT-DISTANCE}(a, b)}{\text{MAX}(a, b)}) * 100 \tag{3.1}$$

En la ecuacion 3.1 se muestra el procentaje del indice de similitud, el cual determina la similitud entre dos archivos de codigo fuente.

3.3.4. Algoritmo SCED

Con los modulos LEXER y GET-EDIT-DISTANCE podemos calcular el porcentaje de similitud entre dos archivos. A continuación la implementación en pseudocódigo del algoritmo propuesto.

SCED-ALGORITHM(*file-A*, *file-B*)
1 *lexer-A* = LEXER(*file-A*)
2 *lexer-B* = LEXER(*file-B*)
3 *tokens-A* = GET-TOKENS(*file-A*)
4 *tokens-B* = GET-TOKENS(*file-B*)
5 *edit-dis* = GET-EDIT-DISTANCE(*tokens-A*, *tokens-B*)
6 *max-length* = MAX(*tokens-A.length*, *tokens-B.length*)
7 *percentage* = $(1 - \textit{edit-dis}/\textit{max-length}) * 100$
8 **return** *percentage*

3.4. Implementación en Python del algoritmo

3.4.1. Pygments

Pygments es una libreria de codigo abierto escrita en el lenguaje de programacion de Python, Brandl, Georg and Chajdas, Matthaus (2022) explica que *Pygments* es un resaltador de sintaxis generico, es utilizado en foros, wikis u otros aplicaciones que necesitan embellecer el codigo fuente entre sus características se tiene:

- Admite una amplia gama de lenguajes son 533 en total, y otros formatos de texto.
- Soporte nuevos lenguajes y formatos, se agrega facilmente, utilizan un mecanismo de lectura simple basado en expresiones regulares.
- Tiene varios formatos de salida disponibles, entre ellos secuencias *HTML*, *RTF*, *Latex* y *ANSI*.
- se puede utilizar como herramienta de linea de comandos y como biblioteca.

La biblioteca de *Pygments* tiene un modulo para el analisis lexico llamado *pygments.lexers*. El modulo se encarga de convertir un archivo de codigo fuente en un arreglo de tokens. Tambien tiene un modulo para el manejo de tokens llamado *pygments.token*.

3.4.2. Modulo Lexer

En este modulo se hace uso de la libreria *pygments* para la tokenizacion y clasificacion de los tokens del codigo fuente. Se implementa un procedimiento para calcular el valor hash de las cadenas de los tokens el procedimiento se llama COMPUTE-HASH.

Programa 3.1: Lexer

```
1  import pygments.token as token
2  import pygments.lexers as lexer
3
4  class Lexer:
5    def __init__(self, file_name):
6      self.file_name = file_name
7      self.tokens = []
8      self.dict_keywords = {}
9      self.clean_tokenize()
10
11   def compute_hash(self, s):
12     p = 31
13     m = 1e9 + 9
14     hash_value = 0
15     p_pow = 1
16     for c in s:
17       hash_value = (hash_value + (ord(c) - 97 + 1) * p_pow) % m
18       p_pow = (p_pow * p) % m
19     self.dict_keywords[s] = hash_value
20
21   def get_hash(self, s):
22     if self.dict_keywords.get(s, None) == None:
23       self.compute_hash(s)
24     return self.dict_keywords[s]
25
26   def num_convert(self, num):
27     try:
28       integer = int(num)
29       return integer
30     except Exception as e:
31       try:
32         double = float(num)
```

```
33          return double
34        except Exception as e:
35          return "N"
36
37    def clean_tokenize(self):
38      file = open(self.file_name, "r")
39      text_string = file.read()
40      file.close()
41      lex = lexer.guess_lexer_for_filename(self.file_name, text_string)
42      lex_tokens = lex.get_tokens(text_string)
43      for element in lex_tokens:
44        token_type = element[0]
45        token_value = element[1]
46        if token_type in token.Text:
47          pass
48        elif token_type in token.Keyword:
49          self.tokens.append(self.get_hash(token_value))
50        elif token_type in token.Name.Function:
51          self.tokens.append("F")
52        elif token_type in token.Name:
53          self.tokens.append("V")
54        elif token_type in token.Literal.String:
55          self.tokens.append("S")
56        elif token_type in token.Literal.Number:
57          self.tokens.append("N")
58        elif token_type in token.Operator:
59          self.tokens.append(token_value)
60        elif token_type in token.Punctuation:
61          self.tokens.append(token_value)
62        elif token_type in token.Comment:
63          pass
64        else:
65          self.tokens.append("X")
```

3.4.3. Modulo Sequence-alignment

En este modulo se implementan algoritmos de programacion dinamica que resuelven el problema de la distancia de edicion de dos secuencias. En la implementación se toma en cuenta la reduccion de complejidad espacial y temporal, presentados en el capitulo anterior.

Programa 3.2: Sequence-alignment

```
1 def levenshtein(X, Y):
2   m = len(X) + 1
```

```
  n = len(Y) + 1
  t = [[0 for _ in range(n)] for _ in range(m)]
  for i in range(0, m):
    t[i][0] = i
  for i in range(1, n):
    t[0][i] = i
  for i in range(1, m):
    for j in range(1, n):
      cost = 0
      if not X[i - 1] == Y[j - 1]:
        cost = 1
      t[i][j] = min(t[i - 1][j - 1] + cost, t[i][j - 1] + 1, t[i - 1][
   j] + 1)
  return t[m - 1][n - 1]

def levenshtein_min_space(X, Y):
  if len(Y) > len(X):
    X, Y = Y, X
  m = len(X) + 1
  n = len(Y) + 1
  t = [[i for i in range(n)] for _ in range(2)]
  for i in range(1, m):
    t[0], t[1] = t[1], t[0]
    t[0][0] = i - 1
    t[1][0] = i
    for j in range(1, n):
      cost = 0
      if not X[i - 1] == Y[j - 1]:
        cost = 1
      t[1][j] = min(t[0][j - 1] + cost, t[1][j - 1] + 1, t[0][j] + 1)
  return t[1][n - 1]

def levenshtein_min_time(X, Y, D):
  m = len(X) + 1
  n = len(Y) + 1
  mx = max(len(X), len(Y))
  t = [[mx for _ in range(n)] for _ in range(m)]
  d = ceil(len(Y) * (D / 100))
  for i in range(0, m):
    t[i][0] = i
  for i in range(1, n):
    t[0][i] = i
  for i in range(1, m):
    left = max(1, i - d)
    right = min(n, i + d + 1)
```

```
47      for j in range(left, right):
48        cost = 0
49        if not X[i - 1] == Y[j - 1]:
50          cost = 1
51        t[i][j] = min(t[i - 1][j - 1] + cost, t[i][j - 1] + 1, t[i - 1][
      j] + 1)
52    return t[m - 1][n - 1]
53
54  from math import ceil
55  def levenshtein_min_space_time(X, Y, D):
56    if len(Y) > len(X):
57      X, Y = Y, X
58    m = len(X) + 1
59    n = len(Y) + 1
60    d = ceil(len(Y) * (D / 100))
61    t = [[_ for _ in range(n)] for _ in range(2)]
62    for i in range(1, m):
63      t[0], t[1] = t[1], t[0]
64      t[0][0] = i - 1
65      t[1][0] = i
66      left = max(1, i - d)
67      right = min(n, i + d + 1)
68      for j in range(left, right):
69        cost = 0
70        if not X[i - 1] == Y[j - 1]:
71          cost = 1
72        t[1][j] = min(t[0][j - 1] + cost, t[1][j - 1] + 1, t[0][j] + 1)
73    return t[1][n - 1]
```

La funcion LEVENHTEIN-MIN-SPACE-TIME es la que se utilizara para el calulo de la distancia de edicion de secuencias, donde tiene como parametro de entrada dos secuencias de tokens y un numero D en el rango $[0, \ldots, 100]$ que representa el porcentaje de las columnas adyacentes a la diagonal principal que se consideran para el calculo de la distancia de edicion.

3.4.4. Modulo SCED-Algorithm

En este modulo se aplican las anteriores implementaciones de algoritmos, y se calcula el porcentaje de similitud de dos codigos fuente.

Programa 3.3: SCED-Algorithm

```
1  from lexer import Lexer
2  from sequence_alignment import levenshtein
3  from sequence_alignment import levenshtein_min_space_time
```

```
4  from sequence_alignment import levenshtein_min_time
5
6  class Sced_algorithm:
7    def __init__(self, file_name_a, file_name_b, D):
8      self.file_name_a = file_name_a
9      self.file_name_b = file_name_b
10     self.D = D
11
12   def get_per_similarity(self):
13     lexer_a = Lexer(self.file_name_a)
14     lexer_b = Lexer(self.file_name_b)
15     tokens_a = lexer_a.tokens
16     tokens_b = lexer_b.tokens
17     edit_dis = levenshtein_min_space_time(tokens_a, tokens_b, self.D)
18     max_len = max(len(tokens_a), len(tokens_b))
19     percentage = (1 - edit_dis / max_len) * 100
20     return percentage
```

3.5. Análisis de complejidad

A continuación el análisis de la complejidad temporal y espacial de cada uno de los procedimientos, la complejidad fue calculada en notación Big O.

3.5.1. Complejidad temporal

1. El modulo LEXER tiene complejidad temporal de $O(t)$ donde t representa el numero de tokens que contiene el archivo $file$.

2. El modulo GET-EDIT-DISTANCE tiene complejidad temporal de $O(m * d)$ donde m y d, representan el número de elementos de la primera secuencias de tokens y el numero de columnas adyacentes a la diagonal principal, donde $d \leq n$ y n es el numero de elementos de la segunda secuencia.

3. El modulo SCED-ALGORITHM hace uso de los anteriores metodos, entonces la complejidad temporal es de $O(t + (m * d))$.

3.5.2. Complejidad espacial

1. El modulo GET-EDIT-DISTANCE tiene complejidad espacial de $O(\text{MIN}(m, n))$ donde m y n, representan el número de elementos de las secuencias de tokens.

CAPÍTULO 4: EVALUACION Y RESULTADOS

4.1. Especificaciones de la prueba

Con los conjuntos y pares de archivos, se realizo la comparación del algoritmo SCAM frente a los algoritmos RKRGST y Winnowing-Fingerprint. El propósito de las pruebas es obtener los resultados sobre el desempeño de los algoritmos, en términos de precisión y tiempo de ejecución en la deteccion de similitud. En la figura 4.1 se ilustra el proceso de las pruebas.

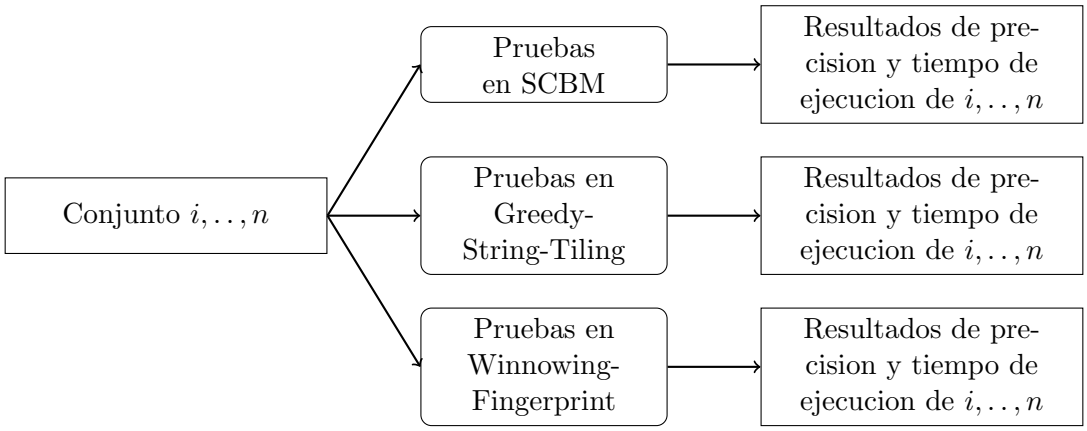

Figura 4.1: Especificacion de las pruebas
Fuente: Elaboración propia.

4.1.1. Pruebas de medicion de precisión en la deteccion de similitud

En estas prueba se midió la precisión del algoritmo SCAM frente a los algoritmos RKRGST y Winnowing-Fingerprint. Para cada para de archivos de un conjunto, se realizó la prueba en complejidad temporal de $O(N^2)$. Es decir para un conjunto, se realizó la comparacion de cada par de archivos del mismo.

La precisión de los algoritmos se determino mediante el porcentaje del indice de similitud entre dos archivos. Los resultados obtenidos de la comparacion de similitud entre archivos del conjunto se almacenó en una matriz, y con escala de grises se observó la similitud que existe. Donde los tonos oscuros representan que existe similitud entre dos archivos y los tonos claros representan lo contrario.

4.1.2. Tiempo de ejecucion de las pruebas de medicion

Con bibliotecas propias del lenguaje de programacion Python se midio el tiempo de ejecucion en segundos de los algoritmos al calcular la similitud en los conjuntos de archivos. La biblioteca

utilizada para la medicion fue *timeit*. Un ejemplo para la medicion del tiempo de ejecucion de un programa se muestra en el programa 4.1.

Programa 4.1: timeit

```
1 from timeit import default_timer
2 start_time = default_timer()
3 # run program
4 elapsed_time = default_timer() - start_time
5 print(elapsed_time)
```

4.2. Prueba de medicion Preliminar

En esta prueba se utilizo los archivos de codigo fuente que se utilizaron en los ejemplos de ofuscacion de codigo fuente, presentados en el marco teorico. En la tabla 4.1 se muestra el detalle de los programas, el identificador del par y las etiquetas de los programas.

Conjunto	Original	Ofuscado
1	Programa 2.1	Programa 2.2
2	Programa 2.3	Programa 2.4
3	Programa 2.5	Programa 2.6
4	Programa 2.7	Programa 2.8
5	Programa 2.9	Programa 2.10
6	Programa 2.11	Programa 2.12
7	Programa 2.13	Programa 2.14
8	Programa 2.15	Programa 2.16

Cuadro 4.1: Detalle de los conjuntos de programas con ofuscacion.
Fuente: Elaboración propia.

En la figura 4.2 se muesta los resultados obtenidos en la prueba preliminar.

4.3. Pruebas de medicion en trabajos de catedra

En estas prueba se utilizo archivos de código fuente en Python enviados por usuarios de un juez de programación. En el cuadro 4.2 se muestra el identificador del conjunto, el numero de problema en el juez, el numero de archivos del conjunto, el promedio de lineas de codigo de los archivos y la varianza de lineas de codigo de los archivos.

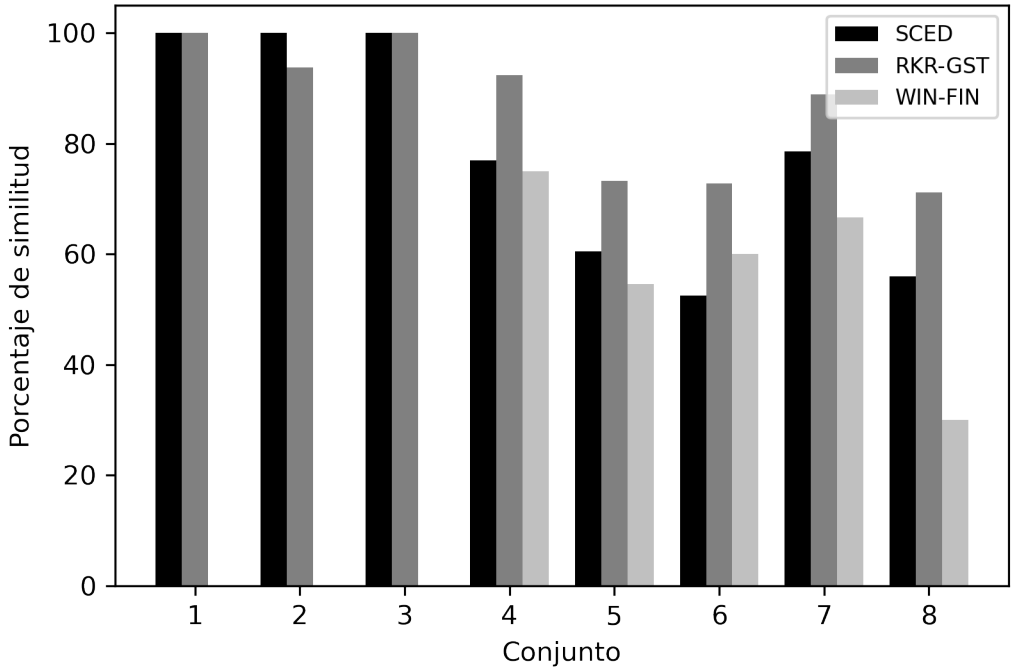

Figura 4.2: Resultados de la prueba preliminar
Fuente: Elaboración propia.

Conjunto	Nro. de Prob.	Nro. de archivos	Prom. de lineas	Var. de lineas
A	1275	10	24.8	70.84
B	1407	25	13.8	8.92
C	1588	41	14.24	39.84
D	1222	76	2.59	0.64
E	1089	101	13.95	22.15

Cuadro 4.2: Detalle de los conjuntos de archivos de código fuente para las pruebas
Fuente: Elaboración propia.

4.3.1. Prueba de medicion I

En la prueba I, se midió la precision y el tiempo de ejecucion de los algoritmos con los siguientes parametros:

- SCED, $D = 40$
- RKRGST, *threshold* $= 80$

- Winnowing-Fingerprint, $window\text{-}length = 10, k\text{-}grams = 5$

Conjunto A

En la figura 4.3 se muestra la matriz que se obtuvo para el conjunto A.

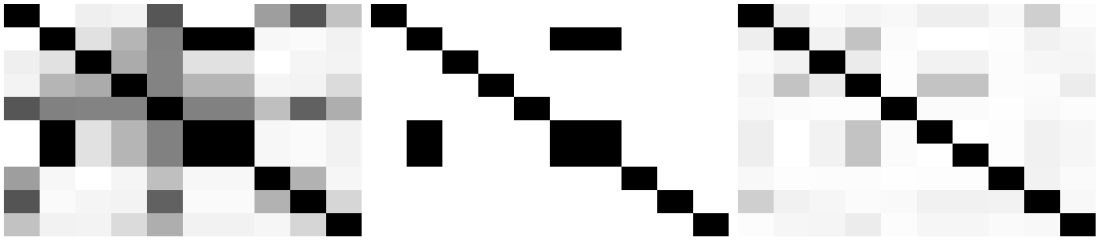

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.3: Prueba de precisión I, conjunto A
Fuente: Elaboración propia.

Conjunto B

En la figura 4.4 se muestra la matriz que se obtuvo para el conjunto B.

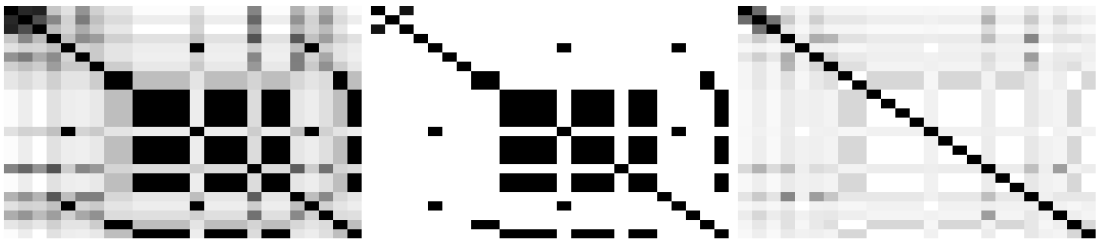

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.4: Prueba de precisión I, conjunto B
Fuente: Elaboración propia.

Conjunto C

En la figura 4.5 se muestra la matriz que se obtuvo para el conjunto C.

Conjunto D

En la figura 4.6 se muestra la matriz que se obtuvo para el conjunto D.

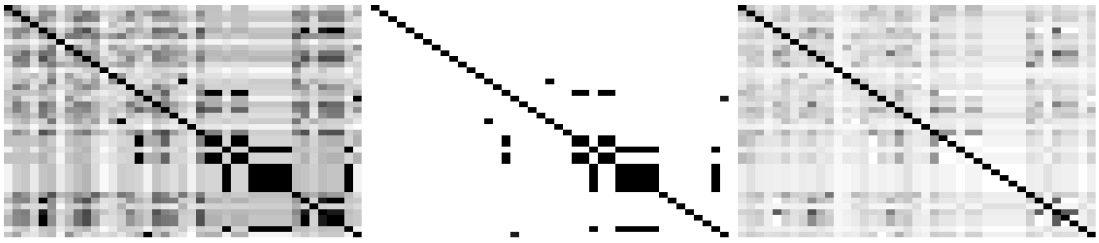

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.5: Prueba de precisión I, conjunto C
Fuente: Elaboración propia.

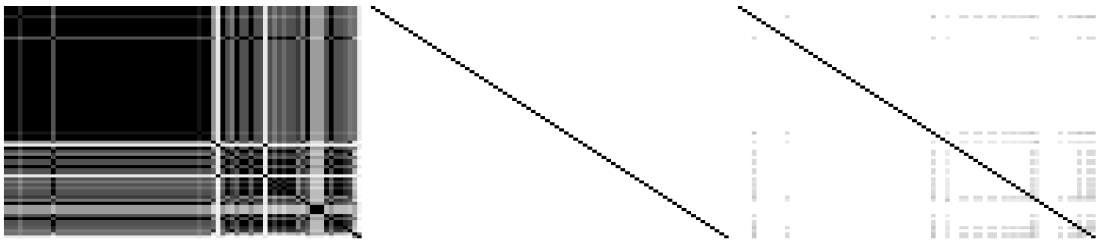

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.6: Prueba de precisión I, conjunto D
Fuente: Elaboración propia.

Conjunto E

En la figura 4.7 se muestra la matriz que se obtuvo para el conjunto E.

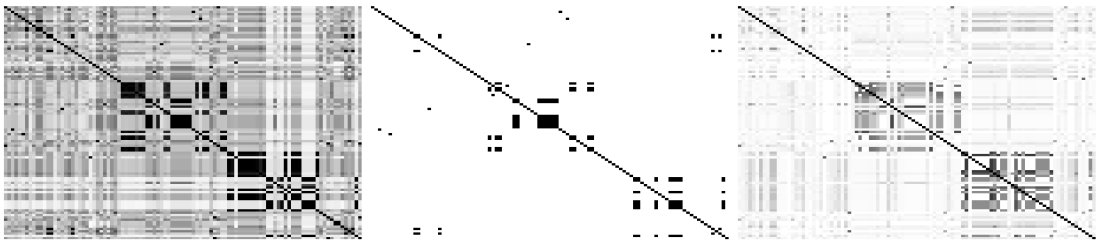

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.7: Prueba de precisión I, conjunto E
Fuente: Elaboración propia.

4.3.2. Tiempo de ejecución de la prueba de medicion I

En la tabla 4.3 se presentan los resultados obtenidos, respecto al tiempo de ejecucion de cada algoritmo al calcular la similitud de cada conjunto de prueba. Los resultados obtenidos se encuentran en segundos.

Conjunto	Nro. Pares	Prom. tiempo de ejecucion		
		SCED	RKRGST	WF
A	45	1.69	0.90	0.84
B	300	4.52	3.05	3.46
C	820	9.93	7.81	8.65
D	2850	19.06	1.90	8.17
E	5050	47.76	27.88	43.48

Cuadro 4.3: Detalle del promedio de tiempo de ejecución de los algoritmos en la Prueba I.
Fuente: Elaboración propia.

4.3.3. Prueba de medicion IV

En la prueba II, se midió la precision y el tiempo de ejecucion de los algoritmos con los siguientes parametros:

- SCED, $D = 100$
- RKRGST, $threshold = 20$
- Winnowing-Fingerprint, $window\text{-}length = 4, k\text{-}grams = 2$

Conjunto A

En la figura 4.8 se muestra la matriz que se obtuvo para el conjunto A.

Conjunto B

En la figura 4.9 se muestra la matriz que se obtuvo para el conjunto B.

Conjunto C

En la figura 4.10 se muestra la matriz que se obtuvo para el conjunto C.

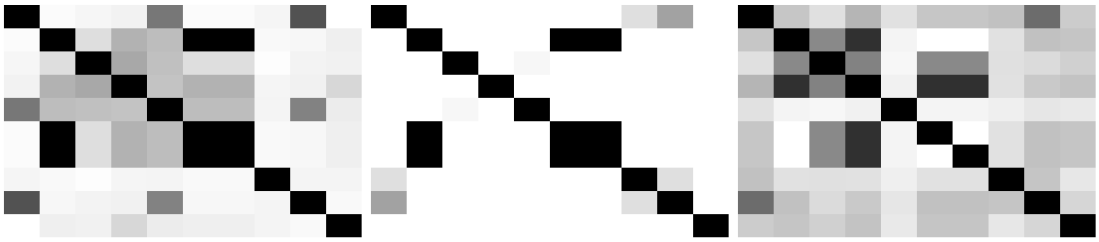

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.8: Prueba de precisión IV, conjunto A
Fuente: Elaboración propia.

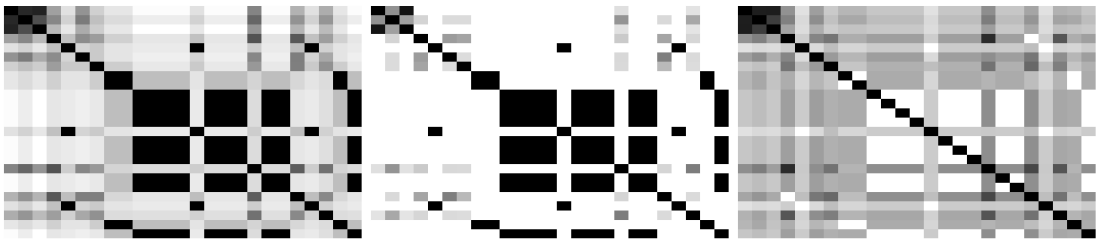

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.9: Prueba de precisión IV, conjunto B
Fuente: Elaboración propia.

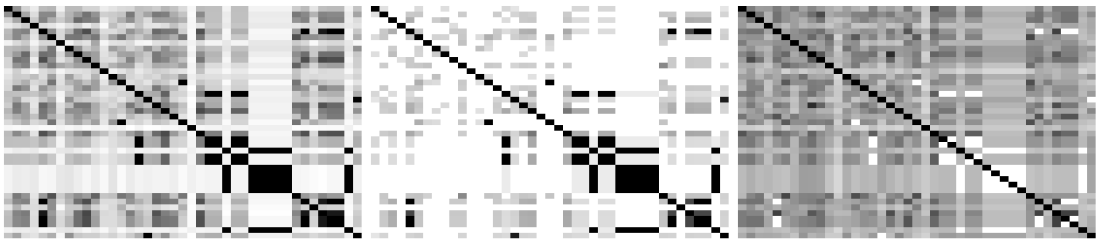

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.10: Prueba de precisión IV, conjunto C
Fuente: Elaboración propia.

Conjunto D

En la figura 4.11 se muestra la matriz que se obtuvo para el conjunto D.

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.11: Prueba de precisión IV, conjunto D
Fuente: Elaboración propia.

Conjunto E

En la figura 4.12 se muestra la matriz que se obtuvo para el conjunto E.

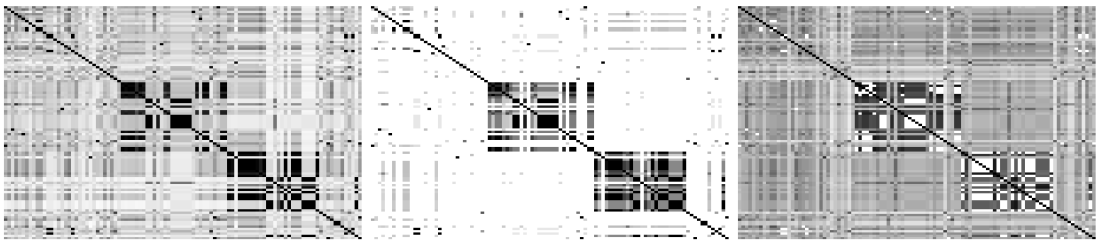

(a) SCED (b) Greedy-String-Tiling (c) Winnowing-Fingerprint

Figura 4.12: Prueba de precisión IV, conjunto E
Fuente: Elaboración propia.

4.3.4. Tiempo de ejecución de la prueba de medicion IV

En la tabla 4.4 se presentan los resultados obtenidos, respecto al tiempo de ejecucion de cada algoritmo al calcular la similitud de cada conjunto de prueba. Los resultados obtenidos se encuentran en segundos.

Conjunto	Nro. Pares	Prom. tiempo de ejecucion		
		SCED	RKRGST	WF
A	45	1.80	0.92	0.83
B	300	5.11	3.08	3.59
C	820	10.98	7.92	8.95
D	2850	19.20	1.90	9.00
E	5050	53.61	28.30	47.03

Cuadro 4.4: Detalle del promedio de tiempo de ejecución de los algoritmos en la Prueba IV.
Fuente: Elaboración propia.

4.4. Prueba de hipotesis

Para la prueba de hipotesis se utilizó como muestra, las mediciones obtenidas de los conjunto A, B, C, D, E durante la prueba de medicion IV. Se escogio la prueba IV porque tiene la mejor configuracion de parametros para los algoritmos. En la tabla 4.5 se muestra los estadisticos descriptivos de la muestra.

	N	Media	Desv. estándar	Mínimo	Máximo
RKRGST y WF	9065	47.81	28.85	0.00	100.00
SCED	9065	61.65	22.38	25.42	100.00

Cuadro 4.5: Estadisticos descriptivos de la muestra
Fuente: Elaboracion propia.

4.4.1. Prueba de normalidad

Antes de escoger el estadistico para la prueba de hipotesis, se debe comprobar si la muestra esta distruida de forma normal, como el numero de datos es grande se utiliza la prueba de normalidad de Kolmogorov-Smirnov. Esta prueba se la realiza con las diferencias entre las mediciones de la muestra, para dos conjuntos de mediciones $A = a_1, a_2, .., a_m$ y $B = a_1, a_2, .., a_m$, la diferencia de mediciones esta dado por $C = c_1, c_2, .., c_m$ donde $c_i = a_i - b_i$.

Paso 1. Planteamiento de la hipotesis de normalidad:

H_0 = Los datos de la muestra siguen una distribucion normal

H_1 = Los datos de la muestra no siguen una distribucion normal

Paso 2. Nivel de significancia:

$$N.C. = 0.95$$
$$\alpha = 0.05$$

Paso 3. Prueba de Nornmalidad:

Si $n > 50$ aplicar la prueba de Kolmogorov-Smirnov.

Paso 4. Criterio de decision:

Si *valor-p* $< \alpha$ se rechaza H_0 y se acepta H_1.
Si *valor-p* $\geq \alpha$ se acepta H_0 y se rechaza H_1.

Paso 5. Resultados y conclusion. Como el tamaño de la muestra es $N = 5050$ se aplica la prueba de Kolmogorov-Smirnov y el detalle de los resultados se muestra en la tabla 4.6.

	Estadistico	g.l.	valor-p
C	0.22	9065	0.00

Cuadro 4.6: Estadistico de Kolmogorov-Smirnov
Fuente: Elaboracion propia.

Para los valores obtenidos se tiene que $0.00 < 0.05$, entonces se rechaza H_0 y se acepta H_1. Con el rechazo de hipotesis nula y se aceptacion de la hipotesis de alterna, se puede inferir que los datos no siguen una distribucion normal.

Con esta prueba de normalidad aseguramos que el estadistico para contrastar la hipotesis debe tener enfoque no parametrico.

4.4.2. Prueba de los rangos con signo de Wilcoxon

La prueba de Wilcoxon es una prueba no parametrica alternativa a la prueba T para dos muestras relacionadas, es decir los resultados del primer conjunto no son independientes del segundo conjunto, dado que ambas mediciones se obtuvieron de una misma muestra. Se la utiliza para determinar si la diferencia de medianas de mediciones relacionadas se debe al azar o no. El estadistico se muestra en la siguiente ecuacion 4.1. Los supuestos para esta prueba son: Los datos deben ser dependientes, los datos deben estar medidos a nivel ordinal, no requiere que los datos se distribuyan de forma normal.

$$Z = \frac{W - n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24}} \tag{4.1}$$

Calculo de W

El procedimento para obtener el valor W es el siguiente:

- Calcular las diferencias entre las dos puntuaciones de cada pareja.

$$z_i = x_i - y_i$$

- Calcular el valor absoluto de las diferencias de cada pareja.

$$z_i = |x_i - y_i|$$

- Ordenar los valores absolutos $|z_1|, |z_2|, \ldots, |z_n|$ y asignar su rango. El rango R_i de un número es el tamaño relativo a otros valores en la lista.

- Calcular los estadisticos de prueba de Wilcoxon W^+ y W^+.

$$W^+ = \sum_{z_i>0} R_i$$
$$W^- = \sum_{z_i<0} R_i$$

- Calcular el minimo valor entre W^+ y W^-.

$$W = \text{MIN}(W^+, W^-)$$

Prueba de Wilcoxon

La hipotesis planteada en la investigacion indica que: "El algoritmo SCED detecta la similitud entre codigos fuente con una confiabilidad del 95 % frente a los algoritmos de RKRGST y Winnowing-Fingerprint". Donde las variables que fueron evaluadas son las siguientes:

Variable independiente: El diseño del algoritmo *SCED*

Variable dependiente: Resultados en la deteccion de similitud entre codigos fuente con una confiabilidad del 95 % frente a los algoritmo de RKRGST y Winnowing-Fingerprint.

El procedimento para contrastar la hipotesis de investigacion es el siguiente:

Paso 1. Planteamiento de la hipotesis:

$$H_0 = \mu_d = 0$$
$$H_1 = \mu_d > 0$$

Paso 2. Nivel de significancia:

$$N.C. = 0.95$$
$$\alpha = 0.05$$

Paso 3. Criterio de decision:

Si *valor-p* $< \alpha$ se rechaza H_0 y se acepta H_1
Si *valor-p* $\geq \alpha$ se acepta H_0 y se rechaza H_1

Paso 4. Resultados y conclusion.
Se aplica la prueba de Wilcoxon a la muestra, el detalle de los resultados se muestra en la tabla 4.8.

	N	Rango prom.	Suma de rangos
Rangos negativos	2069	2627.31	5435913.50
Rangos positivos	5630	4299.33	24205236.50
Empates	1366	-	-
Total	9065	-	-

Cuadro 4.7: Rangos de la prueba de Wilcoxon
Los rangos negativos, positivos y empates representan: *SCED* $<$ *RKRGST-WF*, *SCED* $>$ *RKRGST-WF* y *SCED* $=$ *RKRGST-WF*. Fuente: Elaboracion propia.

	SCED vs. RGST-WF
Z	-48.09
valor-p	0.00

Cuadro 4.8: Prueba de rangos con signo de Wilcoxon
El estadistico Z se basa en rangos negativos. Fuente: Elaboracion propia.

Para los valores obtenidos se tiene que $0.00 < 0.05$, entonces se rechaza H_0 y se acepta H_1. Con el rechazo de hipotesis nula y se aceptacion de la hipotesis de alterna, se puede inferir que el algoritmo SCED detecta similitud entre codigos fuente con una confiabilidad del 95 % frente a los algoritmos de RKRGST y WF.

CAPÍTULO 5: CONCLUSIONES Y RECOMENDACIONES

5.1. Conclusiones

Se diseño satisfactoriamente el algoritmo SCED de acuerdo a los objetivos planteados. El algoritmo SCED para la deteccion de similitud entre codigos fuente se basa el calculo de la distancia de edicion de codigos fuente tokenizados. Apartir de las pruebas de medicion realizadas en trabajos de catedra se obtienen las siguientes conclusiones:

- El algoritmo detecta similitud entre codigos fuente que contienen metodos de ofuscacion.
- El algoritmo SCED detecta la similitud con una confiabilidad del 95 % frente a los algoritmos Running-Karp-Rabin Greedy-String-Tiling y Winnowing-Fingerprint.
- Se observo que la tecnica de programacion dinamica, utilizada en la deteccion de similitud entre codigos fuente obtiene mejores resultados frente a otras tecnicas.

5.2. Recomendaciones

El presente trabajo de investigacion hace uso de la distancia de Levenshtein, para el calculo de la similitud entre codigos fuente. Por lo cual se sugieren las siguientes recomendaciones:

- Comparar el algoritmo propuesto frente a otros algoritmos que utilicen la tecnica de programacion dinamica en la deteccion de similitud.
- Desarrollar una herramienta de software para la deteccion de similitud entre codigos fuente, que utilice el algoritmo SCED.
- Aplicar al algoritmo SCED otros tipos de distancia de edicion como: La distancia de la subsecuencia comun mas larga, la distancia Hamming, la distancia Damerau-Levenshtein y la distancia Jaro-Winkler.
- Realizar mediciones de similitud con el algoritmo SCED en codigos fuente de escritos en diferentes lenguajes de programacion.

Referencias

Aho, A. (2008). *Compiladores: principios, tecnicas y herramientas*. Pearson Educacion, Mexico.

Ahtiainen, A., Surakka, S., y Rahikainen, M. (2006). Plaggie: Gnu-licensed source code plagiarism detection engine for java exercises. *ACM International Conference Proceeding Series*, 276.

Anzai, K. y Watanobe, Y. (2019). Algorithm to determine extended edit distance between program codes. pp. 180–186.

Bejarano, A., García, L., y Zurek, E. (2015). Detection of source code similitude in academic environments. *Computer Applications in Engineering Education*.

Brandl, Georg and Chajdas, Matthaus (2022). Pygments: Python syntax highlighter. https://pygments.org. [Online; accessed 27-May-2022].

Catalán, J. (2010). *Compiladores : teoría e implementación*. RC Libros, San Fernando de Henares, Madrid.

Cheers, H., Lin, Y., y Smith, S. (2021). Academic source code plagiarism detection by measuring program behavioural similarity.

Collberg, C., Thomborson, C., y Low, D. (1997). A taxonomy of obfuscating transformations. *http://www.cs.auckland.ac.nz/staff-cgi-bin/mjd/csTRcgi.pl?serial*.

Cormen, T. H., Leiserson, C. E., Rivest, R. L., y Stein, C. (2009). *Introduction to Algorithms*. The MIT Press. MIT Press, London, England.

Cosma, G. y Joy, M. (2012). An approach to source-code plagiarism detection and investigation using latent semantic analysis. *IEEE Trans. Computers*, 61:379–394.

Donaldson, J. L., Lancaster, A.-M., y Sposato, P. H. (1981). A plagiarism detection system. pp. 21–25.

Faidhi, J. y Robinson, S. (1987). An empirical approach for detecting program similarity and plagiarism within a university programming environment.

Grier, S. (1981). A tool that detects plagiarism in pascal programs. En *Proceedings of the Twelfth SIGCSE Technical Symposium on Computer Science Education*, SIGCSE '81, p. 15–20, New York, NY, USA. Association for Computing Machinery.

Hage, J., Rademaker, P., y Van Vugt, N. (2010). A comparison of plagiarism detection tools. *Utrecht University. Utrecht, The Netherlands*, 28(1).

Halim, F. y Halim, S. (2019). *Programacion competitiva*. Independently Published.

Karnalim, O. y Simon, Chivers, W. (2019). Similarity detection techniques for academic source code plagiarism and collusion: A review.

Magurran, A. E. (1988). *A variety of diversities*. Springer.

Marzieh, A., Mahmoudabadi, E., y Khodadadi, F. (2011). Pattern of plagiarism in novice students

generated program: An experimental approach. *The Journal of Information Technology Education*, 10.

Moussiades, L. y Vakali, A. (2005). Pdetect: A clustering approach for detecting plagiarism in source code datasets. *The Computer Journal*, 48.

Navarro, G. (2001). A guided tour to approximate string matching. *ACM Comput. Surv.*, 33:31–88.

Novak, M., Joy, M., y Kermek, D. (2019). Source-code similarity detection and detection tools used in academi: A systematic review. *ACM Trans. Comput. Educ.*, 19(3).

Ottenstein, K. J. (1976). An algorithmic approach to the detection and prevention of plagiarism. *SIGCSE Bull.*, 8(4):30–41.

Pachón, H. (2019). *Generación de un algoritmo para el análisis de similitudes de código fuente en lenguajes Java y Python*. Uniandes.

Popescu, D. y Nicolae, D. (2016). *Determining the Similarity of Two Web Applications Using the Edit Distance*, volumen 356.

Prechelt, L. y Malpohl, G. (2003). Finding plagiarisms among a set of programs with jplag. *Journal of Universal Computer Science*, 8.

Ragkhitwetsagul, C., Krinke, J., y Clark, D. (2018). A comparison of code similarity analysers. *Empirical Softw. Engg.*, 23(4):2464–2519.

Sidorov, G., Romero, M., Markov, I., Guzman-Cabrera, R., Chanona-Hernández, L., y Castillo, F. (2017). Measuring similarity between karel programs using character and word n-grams. *Programming and Computer Software*, 43:47–50.

Song, H.-J., Park, S.-B., y Park, S. (2015). Computation of program source code similarity by composition of parse tree and call graph. *Mathematical Problems in Engineering*, 2015:1–12.

Whale, G. (1990). Software metrics and plagiarism detection. *Journal of Systems and Software*, 13(2):131–138. Special Issue on Using Software Metrics.

Wise, M. (1992). Detection of similarities in student programs: Yap'ing may be preferable to plague'ing. *ACM SIGCSE Bulletin*, 24:268–271.

Yasaswi, J., Purini, S., y Jawahar, C. (2017). Plagiarism detection in programming assignments using deep features. pp. 652–657.

Đurić, Z. y Gašević, D. (2012). A Source Code Similarity System for Plagiarism Detection. *The Computer Journal*, 56(1):70–86.